

Co-Pilot AI Scientist v3：面向协作式自动科研的洞察门控科研演化

摘要

自动科研智能体已经可以提出假设、运行实验、撰写论文并优化代码，但它们仍缺少一种原则化方式来利用人类科研品味：也就是人类判断哪些问题、失败、机制或主张边界更值得追求的非指标化能力。普通

co-pilot

工作流往往把人类当作审批者或编辑者；完全自动化系统则可能移除科学研究中最关键的判断。本论文提出洞察门控科研演化（Insight-Gated

Research

Evolution,

IGRE），把人类科研品味与专家评审洞察转化为

AI

Scientist-v2

式科研循环中的显式控制信号。IGRE

包含五类门控：科研品味先验、评估器压力测试、前沿方向调度、可验证微演化、主张校准。本文进一步提出时间前沿回放（Temporal

Frontier

Replay,

TFR），用离线回放协议检验历史同行评审是否本可以把自动科研引向后来的学科轨迹。IGRE

与

TFR

共同使人类参与不再被默认视为正向影响，而是可以被测量和审计：门控记录证据、注意力成本和主张边界，历史评审信号则根据未来前沿证据接受回放检验。我们基于

FML-bench

式运行、OpenEvolve

式微演化实验、OpenReview

专家评审信号、成对论文生成探针、TFR

审计和

clean-clone

可复现性检查构建证据包。当前证据支持一个保守结论：专家评审文本可以映射为可行动的工作流门控；评审引导的再生成在跨模型复审下能改善部分科研产物；TFR

已经被操作化但当前对

delayed-value

证据为负向；短预算人类门控

FML

运行则是混合或负向结果，而不是自动优于全自动基线。因此本文不是“人类总能提升自动科研”的证明，而是一种用于设计、比较和审计人类洞察如何改变科研搜索过程的可复现方法。

1.

引言

近期

AI

科研智能体已经展现出很强的自动化能力。AI

Scientist-v2

可以生成想法、运行实验并产出论文。AI

Co-Scientist

式系统通过生成、讨论和演化组织假设前沿。AlphaEvolve

则表明，当候选程序可以被自动评估时，语言模型能够驱动演化式代码搜索。这些系统容易导向一个诱人的结论：只要

benchmark

和

evaluator

足够清楚，人类就可以从科研循环中移除。

但科学研究并不只是优化一个可见指标。科学家还要判断哪些问题深刻，哪些失败有信息量，哪些机制值得拆解，哪些结果不足以支撑强主张。这些判断常被称为科研品味或洞察。它们无法完全被

benchmark

分数捕捉，但也不是不可观察的玄学：它们具体出现在论文评审、rebuttal、组会讨论、主张审计以及放弃或重构研究方向的决策中。

因此本文不问“人类参与是否总是优于全自动科研”这个过于粗糙的问题。本文的问题是：哪些人类参与形式可以转化为工作流控制信号，从而改善自动科研的搜索过程或责任边界？这个问题更重要，因为人类参与本身具有高方差。一个人类门控可能把系统引向罕见的高价值方向，也可能拖慢运行、引入偏见、过拟合个人品味，或者选择比全自动策略更差的分支。可信的

co-pilot

方法必须同时测量正面和负面影响。

我们提出

IGRE，这是

Co-Pilot

AI

Scientist

v3

的核心算法模式。IGRE

受已有自动科研系统启发，但不是把几篇论文的方法拼接在一起。它围绕一个不同对象重新组织这些思想：不是单纯追求全自动发现，而是在自动科研循环中识别人类科研品味适合介入的位置，并把这种介入变成可记录、可比较、可审计的搜索算子。IGRE

可以改变研究方向先验，压力测试评估器，调度假设前沿，触发小规模可验证程序搜索，或校准最终论文主张。

因此本文的主张被有意收窄：专家评审与人类科研判断可以被操作化为可审计的工作流控制信号，而这些信号的有效性可以通过实验比较。我们不声称当前

co-pilot

系统已经优于全自动

AI

Scientist-v2。本文贡献包括四点。第一，定义

IGRE

作为人类引导自动科研的五门控架构。第二，发布包含双语论文、脚本、日志、门控

schema、审计文件和可复用

Codex

skill

的可复现证据包。第三，提出时间前沿回放（Temporal

Frontier

Replay,

TFR），用历史同行评审检验人类洞察是否本可以把自动科研引向后来的学科轨迹。第四，在报告正向工作流探针的同时，也报告混合和负向短预算结果，明确主张边界：当前

IGRE

支持的是工作流设计和测量就绪性，而不是顶会级别的

co-pilot

优越性证明。

2.

相关工作

AI

Scientist-v2

代表全自动科研智能体路线：生成想法、执行实验、撰写论文并评估输出。它的优势是端到端自动化，但人类科研品味并不是其算法中的一等对象。AI

Co-Scientist

式工作强调假设生成、批判、排序和演化，与

IGRE

同样把科研看成前沿搜索；但

IGRE

增加了显式人类门控、注意力成本日志和主张校准。

AlphaEvolve

和

OpenEvolve

启发了

IGRE

的可验证微演化门控。它们表明，语言模型生成的代码修改可以通过自动评估进行演化。IGRE

对此采取选择性使用：只有当目标可机器评分且额外搜索成本合理时，才触发微演化，而不是把程序搜索当作所有问题的通用替代。

人机

co-pilot

系统通常提供辅助、编辑或审批。IGRE

的区别在于把人类角色算法化：一次人类介入必须被分类、记录、连接到证据，并根据下游结果接受审计。

重点不是假设每条人类意见都有用，而是识别哪些意见能作为科研搜索控制信号。

OpenReview

等同行评审数据集为这个问题提供了重要代理。真实评审包含人类对新颖性、评估、正确性、清晰度、影响力和主张边界的判断。它们不完美、有噪声、且是回顾性的，但它们是少数大规模公开的人类专家科研品味痕迹。IGRE

不把它们当成实时

co-pilot

数据的替代品，而是把它们作为参与模式设计的离线测试床。

3.

方法：洞察门控科研演化

IGRE

把一次科研运行建模为一连串机器动作与显式门控的交替过程。每个门控都可以改变下一步动作，但必须记录理由、证据、成本和主张边界。这样，人类参与就能被审计，并能与全自动基线比较。

第一类门控是科研品味先验。它在昂贵实验之前选择或重加权研究方向。有效的品味先验不能只是模糊偏好，而要说明一个方向为什么有问题深度、新颖潜力、机制价值、失败信息量、benchmark 适配性或非对称上行收益。当前证据包用

OpenReview

的

novelty

和

impact

类评论作为离线代理。

第二类门控是评估器压力测试。它检查指标是否过于容易、狭窄或可被投机取巧。自动科研尤其需要这一门控，因为智能体可能优化

evaluator

却偏离科学目标。关于缺少

baseline、指标薄弱、数据泄漏、消融不足或比较无效的评审意见会被路由到这里。

第三类门控是前沿方向调度。它作用于假设或实现分支组合。人类或评审派生信号不是在最后审批单个输出，而是在搜索过程中决定哪部分前沿应该获得更多预算。当前期分数不等于长期价值时，这一门控尤其重要。

第四类门控是可验证微演化。它把

OpenEvolve

式程序搜索用于狭窄、可机器评分的子问题，例如启发式设计、向量化、表格建模或小型组合优化目标。IGRE

把它视作升级算子：当任务简单、评估昂贵或搜索相对强

baseline

没有明显边际价值时，直接编辑仍然更合适。

第五类门控是主张校准。它编辑的是论文层面的证据解释，而不只是语言润色。它决定一个结果究竟支持优越性、可行性、测量就绪性、负结果，还是只能作为未来工作。许多专家评审真正有用之处，正是迫使作者收缩主张边界。

这些门控形成如下算法循环：系统提出研究前沿，评估早期产物，把人类或评审派生信号映射为门控动作，更新前沿或

evaluator，必要时执行微演化，最后生成经过主张审计的论文。每个门控记录门控类型、被审查产物、候选选项、决策、理由、预期收益、潜在伤害、注意力成本和下游证据。这一结构使

IGRE

区别于非正式

co-pilot

互动。

IGRE

还包含一个离线学习与评估模式：时间前沿回放（Temporal Frontier

Replay,

TFR）。TFR

的作用，是把回顾性的同行评审数据转化为科研品味测试，而不只是又一个论文质量 rubric。给定时间

t

的历史论文、它收到的评审意见，以及时间

t

+

δ

的后续学科证据，TFR

构造三个回放条件：paper-only、review-guided

和

shuffled-review-control。然后它检验

review-guided

回放究竟只是改善了局部产物质量，还是也把生成的研究计划推向了后来的主流或

SOTA

方向。delayed-value

signal

指的是时间不对称情形：评审引导可能让短期产物在即时评分上更差，但却更接近后来的学科演化方向。这正是

IGRE

试图保留的人类科研品味。

TFR

不是额外搬来的

benchmark，而是

co-pilot

问题本身要求的方法调整。普通

benchmark

比较的是一个分支现在是否获胜；TFR

比较的是一条人类评论是否改变了

agent

未来应该搜索什么。当前证据包通过确定性

smoke、引用驱动前沿

probe、评审-前沿信号挖掘和语义前沿

judge

实现

TFR。这些

probe

规模仍小，而且目前对

delayed-value

证据是负向的；但它们使高尾部假设变得可证伪：有用的人类洞察必须被路由、回放，并根据未来前沿接受检验，而不能因为它来自人类评审就被默认视为有价值。

4.

实验

实验目标是比较人类参与模式，而不是证明人类总是胜过自动化。证据包围绕四个问题展开。

主要量化证据如下表所示。表中有正向、混合和负向结果，因为IGRE
被评估为一种门控选择框架，而不是保证提升性能的技巧。

|
探针
|
Co-pilot
或
review-guided
结果
|
Baseline
或
autonomous
结果
|
增量或胜负
|
解释
|
|

|
---:
|
---:
|
---:
|

|
|
Review
utility
map
|
398
条可行动片段
|
64
条噪声片段
|
共
473
条片段
|
专家评审包含可路由的
taste/insight
信号。
|
|
门控结构消融
|
full
IGRE
utility
capture
1.000
|
最佳单中核

###

4.1

专家评审文本能否映射为有用的工作流门控？

我们通过流式访问

Hugging

Face

上的

nhop/OpenReview

数据集，避免完整下载。探针确认数据集包含

34,638

行，并抽样

160

行。从这些样本中，确定性

review-utility

map

提取

473

条评审片段，其中

398

条被标记为可行动信号，64

条被标记为噪声或低行动性信号。

最常见的可行动路由是评估器压力测试，共

245

次触发。结构化反馈有

210

次触发，主张校准

140

次，科研品味先验

111

次。从类别看，评价和指标问题出现

205

次，局限性和主张边界问题

140

次，新颖性和定位问题

111

次，可复现性问题

79

次，方法正确性问题

71

次。

随后我们在同一
review-utility
map
上运行门控结构消融。no-gate
策略捕获不到可行动路由
utility。最佳单门控是
evaluator
stress
testing，只能捕获
0.369
的可用
utility；structured
feedback
捕获
0.295；claim
calibration
捕获
0.187；scientific-taste
prior
捕获
0.148。128
个
seed
的随机门控基线平均捕获
0.199。完整
IGRE
保留五类显式门控，因此捕获
1.000。这个消融不证明最终论文一定更好，但它说明
IGRE
的结构动机：人类评审洞察不是一个泛泛审批信号，如果压缩为单一
gate，就会系统性丢失科研品味、评估设计和主张边界信息。

最后，我们使用

6

个等上下文

OpenReview

再生成

pair

运行下游门控-结果归因探针。该探针把每篇论文的

review-derived

gate

utility

与

GPT

和

Claude

评分器观察到的

review-guided

减

context-control

分数增量相连。完整

IGRE

的

aligned-outcome

score

为

75.17；最佳单门控

evaluator

stress

testing

为

37.25；512

个

seed

的随机单门控基线均值为

15.26。观察到的最强下游对齐来自

evaluator

stress

testing、structured

feedback

和

scientific-taste

prior。frontier

steering

与

claim

calibration

在这个

6

篇子集中没有非零信号，因此这只是事后归因信号，不是五类门控的因果下游证明。

随后我们运行因果风格的单门控产物消融。对于每篇选中论文，我们分别只给

title/abstract

加上一类

gate-specific

评审片段，生成新的

mini-paper

artifact，并与

title/abstract

baseline

和

full

review-guided

artifact

在

GPT

与

Claude

评分器下比较。最佳单门控条件是

evaluator

stress

testing, mean

overall

为

3.6667 ; full

review-guided

为

3.5 ; baseline

为

2.9166。 winner

votes

分别为

baseline

3、 full

review-guided

2、 evaluator

stress

testing

6、 structured

feedback

1. 这个结果重要之处在于它并不是简单支持“人类越多越好”。它说明

targeted

evaluator-stress

review

在小规模

proxy

中可能比输入全部评审更有用，而对信息充分的摘要， baseline

仍可能有竞争力。因此

IGRE

需要的是门控选择，而不是最大化人类上下文。

这支持用户提出的核心直觉：人类真实论文评审意见就是科研品味和科研洞察的具体痕迹。但有用的并不是所有评审文本，而是其中能够改变

evaluator

设计、搜索方向、论文结构或主张边界的部分。

###

4.2

评审引导的再生成是否改善科研产物？

我们选择

6

篇

ML/AI

OpenReview

论文并生成成对

mini-paper

产物。baseline

条件只使用标题和摘要；review-guided

条件额外使用真实评审片段和

decision

文本。初始评分器偏好

review-guided

产物

5/6

次，平均

overall

score

从

3.0

提升到

3.8333。

为降低同模型评分偏差，我们用更严格的跨模型复审重新评分同一批

6

对产物。在该复审中，review-guided

胜出

3/6

次，baseline

胜出

1

次，2

次平局，平均增量缩小为

+0.1667。保守结论是：当评审文本带来具体方法细节、实验特异性、局限意识或主张校准时，它是有用的；当反馈过于泛化，或使再生成产物丢失原始技术框架时，它并不自动有益。

这个探针还有一个重要混淆：review-guided
条件比
title/abstract
baseline
获得了更多信息。因此我们进一步运行等上下文消融，用等长无关
OpenReview
片段生成
context-control
条件。跨两个
reviewer
模型和
6
篇论文， review-guided
获得
8
个胜出票， context-control
获得
1
个胜出票， 3
次平局，跨模型平均增量为
+0.5。更严格的
Claude
复审给出
review-guided
胜
3
次、 context-control
胜
0
次、平
3
次， 平均增量
+0.1667。这支持更精确的结论：真实相关评审确实可能提供超过通用
reviewer
pressure
的价值，但主要发生在评审包含具体方法细节或明确主张校准警告时。

4.3
短预算人类门控是否优于全自动基线？

当前

FML-bench

式

prospective

matched

packages

被有意报告为混合或负向结果。在已通过审计的包中，有一个受控

Max-Cut

微任务显示人类选择分支有用；但

3

个

FML-bench

案例中，co-pilot

分支出现失败、平局、中止或无法产生有效

continuation。在重复在线

paired

smoke

中，有效

Causality

运行得到

0

次

co-pilot

benchmark

胜出、1

次

autonomous

胜出、1

次平局；Fairness

运行是

no-valid-branch

失败案例。

这个结果很重要。它阻止论文声称人类参与在短预算平均

benchmark

表现上已经有优势。相反，它强化了本文真正的问题：人类门控必须具体、预算敏感，并且被路由到科研品味和洞察确实能改变轨迹的位置。

###

4.4

何时应该触发可验证微演化？

OpenEvolve

式搜索在某些可机器评分子问题上有效，但并非总是必要。在

vectorization

任务中，直接

rewrite

未通过

correctness

gate，而短程

OpenEvolve

式搜索能保持正确性并找到显著运行时间改进。在

Max-Cut

中，直接编辑已经改善

starter，OpenEvolve

式搜索只带来小幅额外收益。在简单

sklearn

diabetes

回归探针中，直接编辑达到与

OpenEvolve

中位数相当的

RMSE。这个边界条件是

IGRE

的核心：程序搜索应由

evaluator

就绪性和预期边际收益触发，而不是由方法潮流触发。

5.

讨论

IGRE

把人类参与重新定义为高方差搜索算子。这比“人类参与一定正向”更符合科学研究。人类判断可能通过捕捉问题深度、机制、新颖性或主张风险，提高罕见高价值轨迹出现的概率；但它也可能在短预算下拉低平均分数。

OpenReview

实验给出了实践路径。真实评审意见可以用于发现哪些人类洞察有用。关于评估薄弱的意见应触发

evaluator

stress

test；关于新颖性的意见应重塑

taste

prior；关于局限性的意见应触发

claim

calibration；关于表达不清的意见应转化为

structured

feedback。泛泛表扬或泛泛批评则应被赋予较低路由权重。

同行评审数据的过去式属性也可以被转化为测量优势。对于历史论文，后来的学科演化轨迹提供了一个后验前沿目标。因此

IGRE

可以运行回溯式前沿对齐实验：取时间

t

的论文及其评审意见，分别在

paper-only、review-guided

和

shuffled-review-control

条件下重新生成后续研究产物，再判断哪些产物更接近后来主流或

SOTA

科研轨迹。这样，优秀评审不只是“打高分”或“批评严厉”的评审，而是其中可行动意见能够把自动科研工作流推向未来重要问题框定、方法、评估规范、失败模式或主张边界的评审。

该协议的第一次确定性

smoke

给出了一个有意保守的信号。在同一批

6

个

OpenReview

案例上，使用人工指定、尚未经过引用验证的未来前沿

descriptor

和关键词/行动性评分，review-guided

产物只赢

1/6, shuffled-review-control

赢

5/6, review-guided

相对

shuffled

control

的平均分差为

-0.0855。这并不否定协议本身，因为

descriptor

和评分器还只是管线

smoke；但它说明，面向未来前沿的对齐比局部论文质量提升更严格，“好评审”必须由未来相关方向性来定义，而不能只由泛化

reviewer

pressure

定义。

最重要的是时间不对称情形：评审引导重新跑出来的论文，短期看可能比原论文更差，当前

benchmark

或局部论文质量也可能不占优，但它更接近后来学科演化出的主流或

SOTA

方向。这类评审就是

delayed-value

review

signal。它的价值不在于立刻提升下一篇产物，而在于把搜索轨迹改向未来重要方向。如果能从历史评审语料中找到一批这样的信号并总结范式，IGRE

就可以学习什么时候应当让人类科研品味覆盖短期自动化压力。

当前

smoke

还没有找到这种

delayed-value

模式，反而在

3

个案例中发现了相反诊断：评审引导提高了短期模型评分，但降低了启发式未来前沿对齐分数。这个负结果依然有价值，因为它把“局部

reviewer

满意度”和“长期科研方向性”区分开来，而这正是

co-pilot

scientist

必须学会的区分。

引用驱动版本现在扩展到

6

个

OpenReview

样本，并使用

OpenAlex

fallback、词汇相关性过滤和标题重合度

guard

来防止元数据误配。它为

6

篇中的

5

篇取回可用未来前沿术语，共包含

80

条相关性过滤后的后续引用。结果再次偏保守：review-guided

只赢

1

例，paper-only

赢

3

例，shuffled-review

control

赢

1

例，另有

1

例因元数据匹配漂移而不可评分。review-guided

的平均

citation-frontier

分数为

0.21，低于

paper-only

的

0.23

和

shuffled-control

的

0.248。该

probe

发现

0

个

delayed-value

case，并发现

3

个短期正向/长期负向案例。这不是

delayed-value

假设的反证，而是说明当前词汇式前沿指标可能更奖励原论文术语，而不是评审引导带来的方向转移；未来

前沿测量必须先解决引用覆盖、主题相关性、元数据

match-drift，以及语义对齐而不只是词汇重合。

因此我们进一步加入更严格的评审-前沿信号探针，直接把历史评审片段与
citation-derived
frontier
terms
进行比较。在
6
篇论文的
16
条评审片段中，最佳评审片段的未来前沿平均分为
0.1431，而原论文上下文为
0.2369，review-guided
artifact
为
0.1906。没有任何评审片段超过原论文上下文或生成产物，也没有发现
latent
delayed-value
candidate。这个负结果很有用，因为它防止论文把
OpenReview
当成天然有效的人类
taste
来源。更稳妥的结论是：同行评审是一个可扩展的离线
participation-mode
测试代理，但真正有用的
taste/insight
信号必须经过筛选、路由，并用更强的语义式和人类评判式未来前沿指标验证。

为了检查这个负结果是否只是词汇重合指标造成的，我们又运行一个小型语义

judge

probe，使用

Monica

路由的

gpt-4o-mini

作为评判器。judge

同时看到原论文上下文、最佳历史评审片段、review-guided

再生成

artifact，以及后续引用论文的元数据。在

5

个具有未来前沿术语的案例中，paper

context

胜

4

次，review-guided

artifact

胜

1

次。平均

semantic-frontier

分数分别为：paper

context

4.2，review-guided

artifact

3.4，最佳

review

snippet

3.0。唯一的

review-guided

胜例是

knowledge-unlearning

案例，而且它是短期和语义都正向，并不是

delayed-value

case。因此，语义

probe

依然发现

0

个

delayed-value

candidate。这进一步收窄了本文主张：delayed-value

设计在概念上重要，而且现在已经可测量；但当前小规模

OpenReview

样本尚未给出正向证据。

这也让本文的应用意义更具体。目标不是简单证明人类能提高论文质量，而是设计更优的人类参与模式，用实验数据比较这些模式，并构建一种工作流，使人类科研品味在最可能改变科研轨迹的位置发挥作用。

6.

局限性

当前证据仍是

pilot

package。它尚未包含独立人类专家对最终

IGRE

论文或成对再生成产物的评审。实时

co-pilot

轨迹是单作者派生元数据语料，而不是许多科研人员共同使用系统后的总体数据。OpenReview

是离线异步评审数据，不是

AI

Scientist-v2

运行中的实时人类干预。matched-budget

FML

证据样本量不足，而且目前对

benchmark

表现是负向或混合结果。等上下文

OpenReview

消融降低了额外上下文混淆，但尚未完全消除，因为评分仍来自模型路由评审，产物也只是再生成

mini-artifact，而不是盲审专家评分或真实实验重跑。高尾假设，即人类品味可能增加罕见突破概率、即使平均分下降，在概念上重要，但尚未被统计操作化。

这些局限也是未来研究方向。为了把下一步做实，仓库已经准备并预注册了

6

对

OpenReview

再生成产物的盲评包：评审者只看到匿名

A/B

产物、固定

rubric

和评分表模板，condition

key

与分析计划在评分完成前由协调者隐藏保存。该计划把有用的人类

taste

与

insight

定义为能够改变科研控制决策的评审信号，而不是泛泛认可。这还不是实验证据，因为尚未收集独立人类专家评分。更强的研究应把可复用

co-pilot

scientist

skill

部署给大量科研人员，在知情同意和隐私保护下收集门控元数据，跨任务运行

matched

autonomous

与

human-gated

轨迹，并把成对输出交给盲审专家评估。目前，这种实时多研究者数据更可能由主流

agent

公司或大模型公司完成，而不是小型独立项目。IGRE

因此使用

OpenReview

作为可扩展离线代理，并明确标记这一缺口。

7.

结论

Co-Pilot

AI

Scientist

v3

提出

IGRE：一种把人类科研品味和专家评审洞察插入自动科研循环的五门控架构。当前证据并不表明人类参与会自动改善自动科研。它证明的是更具体也更有用的事情：专家评审包含可行动信号；这些信号可以路由到工作流门控；评审引导可以改善部分再生成产物；短预算人类门控必须被审计，因为它们可能失败。IGRE将这一点转化为一种可复现的方法，用于设计和比较人机协作科研模式。