

# Co-Pilot AI Scientist v3：面向协作式自动科研的洞察门控科研演化

作者：何石，新加坡国立大学计算机学院

## 摘要

自动科研智能体已经开始把创意生成、实验执行、benchmark 评估和论文写作连接成闭环。然而，完全自动化的科研流水线仍然难以处理一些关键节点：选择什么问题值得做、如何判断证据强弱、如何解释失败结果、以及哪些结论可以负责任地写进论文。本文提出

Co-Pilot

AI

Scientist

v3

及其核心方法：洞察门控科研演化（Insight-Gated

Research

Evolution,

IGRE）。IGRE

不是把已有科研

agent

直接拼装在一起，而是把其中有用的设计压力重新组织成一个面向高尾部科研产出的过程：自动系统维持广泛、可执行的搜索前沿，人类则在显式

gate

中注入科研品味、风险偏好和主张责任。本文最重要的目标不是证明一个二元命题，即“人类参与是否一定提高论文质量”；而是设计、比较和改进多种人类参与模式，让

AI

难以量化的科研品味和人类

insight

能更好地进入自动科研流程。本文定义一个可复现评估协议，用于比较完全自动、局部

gate

和完整

co-pilot

版本在小型自动科研任务上的表现。核心假设是非对称的：人类参与可能降低短预算

benchmark

的平均表现，但设计良好的人类参与

workflow

可能提高产生高新颖性、高影响力科研结果的概率，而这类高尾部结果才是科学发现中最重要的部分。

1.

## 引言

自动科研的下一步，不应该只是“无人参与的论文工厂”。科学研究不仅是可执行步骤的串联，也包括选择有价值问题、识别弱证据、重新解释失败、决定哪些主张值得提出。已有系统提供了重要启发：假设辩论、可执行实验搜索、以及自动评估驱动的代码演化。但本文的方法目标不同：科研

co-pilot

不应只最大化短期

benchmark

的平均分，还应提高系统进入质变方向的概率，例如更尖锐的问题、更能揭示机制的 evaluator、更有解释力的失败、或者能打开新研究线索的主张。

本文提出

Co-Pilot

AI

Scientist

v3，并把它形式化为洞察门控科研演化。目标不是用随意审批拖慢自动流水线，而是把人类介入视为一种稀缺、高方差的搜索算子，只在科研判断能改变搜索前沿形状的位置触发。本文定义五类

gate：科研品味先验、评估器压力测试、前沿转向、可验证微演化，以及主张校准。

因此，本文真正要回答的是一个 workflow 设计问题：哪一种人类参与模式最能把科研品味转化为有用的搜索压力？IGRE

不假设人类只有一种角色，而是比较上游

taste-prior

selection、evaluator

stress

testing、中途

frontier

steering、选择性

program-search

escalation、针对证据稿件的

structured

feedback，以及最终

claim

calibration

等多种模式。当前实验的作用是用数据塑造这些模式、找出更合适的参与节点和边界条件，包括短预算下完全自动搜索反而更强的负例。这样，本文的实际意义是为自动科研设计更有效的人机协作

workflow，而不是简单判断人类和

AI

谁整体更强。

2.

相关工作

AI

Co-Scientist

将科学发现建模为假设生成、讨论和演化，优势在于研究早期的想象力和证据组织。AI

Scientist-v2

通过

agentic

tree

search

将候选想法转化为可运行实验和论文。AlphaEvolve

使用自动评估驱动代码进化，适合机器可评分问题。FunSearch

是

LLM

引导程序搜索用于数学发现的早期代表。Coscientist

则展示了

LLM

agent

如何连接化学工具和实验自动化。

本文还必须放在  
Schmidhuber  
自指学习和代码自我改进这条更早的谱系中理解。1987  
年的  
self-referential  
learning  
工作已经把  
learning-how-to-learn  
表述为学习过程能够检查和修改自身机制的问题；OOPS  
把程序与搜索过程放进增量式通用搜索；Gödel  
Machine  
把自指问题求解器形式化为在证明改写有收益后才改写自身软件；POWERPLAY  
则持续寻找新任务和  
solver  
modification，同时保持旧任务能力。近年的  
Darwin  
Gödel  
Machine  
和  
Huxley-Gödel  
Machine  
把这条线重新带回  
coding  
agent  
场景，让  
agent  
在  
benchmark、archive  
或  
metaproductivity  
信号下修改自身代码库。IGRE  
不声称解决递归自我改进，而是借用这条线中的验证、归档和能力保持纪律：被演化的对象不是  
agent  
整体源码，而是  
bounded  
research  
artifacts、evaluator、子问题程序和主张边界，并且这些变化必须经过人类  
insight  
gate。  
IGRE  
借鉴这些系统带来的设计压力，但不照搬它们的控制逻辑。它从假设生成系统中吸收多样化  
conjecture  
的需求，但把自由辩论改造成可记录的科研品味先验；它从自动论文系统中吸收可执行实验搜索，但在  
benchmark  
分数不足以决定方向的地方加入前沿转向和主张校准；它从程序演化系统中吸收机器可评分子问题的深度搜索，但通过选择性升级  
gate  
控制成本和适用范围。因此，本文优化的不是单个任务指标，而是一条证据对齐、上限更高的科研轨迹。

###

2.1

与一般科研

co-pilot

的区别

很多

co-pilot

系统把人类看作审批者、提示词编写者、偏好标注者或异常兜底者。IGRE

的算法主张不同：人类对自动科研最重要的贡献，往往是对“什么样的科研值得做”的非指标化先验，也就是科研品味。这种先验很难压缩成单一

reward。它包括：一个问题是否有深度，一个负结果是否揭示机制，一个 benchmark

是否太容易被投机，一个看似当前分数不高的分支是否值得保留，以及一个主指标只小幅提升的结果是否仍然值得写成论文主张。

因此，IGRE

区分了三种在人机协作

agent

中经常被混在一起的角色。偏好是在人类已经看到若干完成选项后选择更喜欢的一个；监督是阻止无效或不安全行为；科研品味则是在结果尚未显现之前改变系统应该搜索什么。第三种才是本文的核心区别。IGRE 不把

taste

强行拟合成完整

reward

model，而是把它记录为结构化、可审计、但保留部分定性判断的

gate

record，用它改变搜索前沿。这样，系统可以诚实评估人类输入：它可能降低平均分，但应该被检验的是它是否提高了少数开创性科研轨迹出现的概率。

3.

方法

Co-Pilot

AI

Scientist

v3

实现的是洞察门控科研演化。IGRE

包含四个机器循环和五个面向人类的算子。机器循环保留自动科研的规模化能力：假设扩展、实验构造、可执行前沿搜索和可验证微演化。人类算子则放在科研品味可能改变“哪些前沿值得继续展开”的位置。

图

1


展示了系统的数据流：研究目标先进入假设循环，再进入实验构造和可执行前沿搜索；对于机器可评分子问题，系统可以升级到基于


OpenEvolve

的可验证微演化；最后进入论文生成和主张校准。每个

gate

都接收结构化的候选前沿，并输出可复现的决策记录。





第一，科研品味先验让人类科学家根据早期指标难以捕捉的标准选择、合并或改写方向：概念新鲜度、领域重要性、上行空间的不对称性，以及即使失败也是否能带来有价值的知识。

第二，评估器压力测试把被选中的假设转化为 benchmark、baseline、消融实验、可执行脚本和拒绝条件。这个 gate

不只问指标是否方便，还要问指标是否会被投机、是否漏掉最低效用、以及如果结果为正是否真的能支撑论文主张。

### 第三，前沿转向

运行在可执行实验分支之上。在预设检查点，系统总结指标、代码快照、错误和新颖性线索。人类科学家可以把预算分给当前主指标并非最优、但科研上行空间更大或失败模式更重要的分支。

#### 第四，可验证微演化

只把机器可评分的子问题交给代码演化引擎。由于官方 AlphaEvolve

没有开源核心系统，本文的可复现实验使用

OpenEvolve  
作为实际实现底座。 OpenEvolve

提供自定义  
evaluator、OpenAI-compatible  
模型路由、MAP-Elites

质量多样性搜索、岛屿种群和可复现随机种子。该算子进化代码、保存候选程序，并把通过验证的改进返回主科研流程。

### 第五，主张校准

gate

把最终论文草稿和证据记录逐条对齐。它会削弱、删除或重写尚未被支持的主张，并记录哪些更强主张仍然是下一阶段

benchmark  
要检验的假设。

[illegible]

每一次人类介入都被记录为结构化数据，包括决策类型、候选选项、理由、影响到的产物和后续结果。这样，人类参与不是隐藏的旁路，而是可复现记录的一部分。

当前  
artifact  
package  
还加入了一条  
retrospective  
full-gate  
trajectory, 覆盖本文提出的全部  
gate  
类型。它把选择窄版  
human-gated  
tree-search  
贡献的  
idea  
gate、拒绝公平性指标投机分支的  
evaluator  
gate、在两个  
Causality  
draft  
中选择较优分支的  
live  
branch  
gate、升级到  
OpenEvolve  
的  
program-search  
gate, 以及把未被证实的优越性主张降级为  
future  
work  
的  
claim  
gate  
串成一条可审计链条。这个轨迹证明了日志格式和证据链可以成立, 但还不是一次所有  
gate  
都在线连续运行的端到端实验。

此外，本文还提供了一个可重新运行的  
full-gate  
trace  
脚本。该脚本读取当前已归档的实验摘要，连续重新计算  
idea、evaluator、branch、program-search  
和  
claim  
五类  
gate  
决策，并输出  
JSON  
与  
Markdown  
artifact。这证明  
gate  
policy  
可以在当前证据包上被程序化执行；但它被明确标注为  
executable  
artifact  
replay，而不是新的在线训练  
run。

在  
replay  
artifact  
之后，我们又在  
ubuntu-heshi  
上跑了一次新的  
online  
full-gate  
smoke  
trajectory。该  
orchestrator  
生成  
idea  
gate，审批低成本  
evaluator  
bundle，启动新的两  
draft  
FML-bench  
Causality  
frontier，选择验证  
MAE  
更低的分支，从所选  
snapshot  
继续运行一步  
AI  
Scientist-v2，同时在同一轨迹中跑一次一轮  
OpenEvolve  
knapsack  
搜索，并写出  
claim-audit  
gate。branch  
frontier  
选择  
step  
2（验证  
MAE  
0.627837）而不是  
step  
1（验证  
MAE  
0.677448）。随后一  
步  
continuation  
的  
test  
MAE  
为  
0.862015，差于所选  
frontier  
的  
test  
MAE  
0.646224；同一轨迹中的  
knapsack  
OpenEvolve  
smoke  
达到



随后，我们为这条  
online  
smoke  
增加了同  
FML  
step  
数的  
autonomous  
baseline。该  
baseline  
使用同一个  
Causality  
任务和  
DeepSeek  
模型，运行三步  
AI  
Scientist-v2，但不进行人类  
branch  
gate。它得到验证  
MAE  
0.354147  
和  
held-out  
test  
MAE  
0.428516，明显优于  
human-gated  
smoke  
continuation  
的  
test  
MAE  
0.862015。因此，这个配对  
smoke  
结果对性能提升主张是负证据，但仍支持更窄的“在线  
co-pilot  
编排可以执行”这一主张。

随后我们把  
same-continuous-trajectory  
paired  
online  
full-gate  
smoke  
模式重复跑了三次，并直接从每条轨迹日志生成完整的  
co-pilot  
和  
autonomous  
manuscript  
artifacts。其中两条  
Causality  
run  
有有效标量测试指标：co-pilot  
continuation  
的平均  
test  
MAE  
为  
0.754120，同轮  
autonomous  
baseline  
的平均  
test  
MAE  
为  
0.643337；在  
lower-is-better  
的  
Causality  
指标上，汇总结果是  
0  
次  
co-pilot  
benchmark  
胜、1  
次  
autonomous  
胜、1  
次打平。第三条  
run  
切换到  
Fairness\_fairlearn，并被归档为  
no-valid-branch  
failure-mode  
trajectory，co-pilot  
和  
autonomous  
都没有得到有效标量测试指标。Monica  
路由的  
A/B  
模型评审在三条轨迹的六次  
reviewer  
call  
中都偏好  
co-pilot

我们现在还补了一条  
live  
AI  
Co-Scientist-style  
hypothesis-frontier  
smoke。该前端通过  
Monica  
路由的  
gpt-4o-mini  
做了两次真实模型调用：第一次为  
IGRE  
下一阶段证据里程碑生成  
4  
个候选  
research  
frontiers，第二次按  
AI  
Scientist-v2  
的保守证据纪律对它们进行  
critique  
和  
ranking。模型选择的下一预算候选是  
frontier\_004，即  
structured  
human  
feedback  
mechanism，用来比较  
rubric-guided  
feedback  
和  
informal  
feedback  
对  
reproducibility  
与  
clarity  
的影响。这个  
artifact  
缩小了  
AI  
Co-Scientist  
部分的编排缺口：系统现在有了可记录的  
generate-critique-rank  
假设前端。但它还不能证明该候选会改善下游  
benchmark  
或论文质量，也不是一次人类选择结果。

随后，我们加入了一个  
autonomous  
hypothesis-front-end  
baseline。脚本  
run\_hypothesis\_frontend\_baseline.py  
复用已归档的  
IGRE  
candidate  
portfolio，让同一个模型生成一个没有显式  
human-taste  
gate  
或  
structured  
human  
feedback  
的  
autonomous  
AI  
Scientist-v2-style  
portfolio，再用固定  
rubric  
比较两个  
portfolio。评分器偏好  
IGRE (overall  
4  
vs.  
3)，理由是  
IGRE  
在  
evidence  
gain、benchmark  
fit、claim  
calibration  
和  
human-taste  
visibility  
上更强；但  
autonomous  
portfolio  
在探索完全自动流程变体方面更强。这个  
probe  
只比较前端研究方向  
portfolio，不能说明下游  
benchmark、论文质量或人类专家判断更好。

因此，我们继续为  
frontier\_004  
跑了一个小型  
downstream  
structured-feedback  
probe。脚本  
run\_structured\_feedback\_probe.py  
从同一份已归档  
co-pilot  
manuscript  
出发，通过  
Monica  
路由的  
gpt-4o-mini  
做了  
5  
次真实调用：生成  
free-form  
informal  
feedback、生成  
IGRE-structured  
feedback、分别基于两种  
feedback  
修订同一份稿件，并用固定  
rubric  
对两版修订进行模型评分。评分器偏好  
structured-feedback  
revision (overall  
5  
vs.  
4)，并在  
clarity、reproducibility、claim  
calibration、evidence  
grounding、method  
distinctness、limitation  
honesty  
和  
novelty  
preservation  
上给出更高分。这个结果只能被理解为  
measurement-readiness  
evidence：它说明  
IGRE  
feedback  
格式可以被操作化，并能在模型路由评估中造成可测的稿件修订差异；它不是独立人类专家评审，也不是多  
任务结果，更不能证明人类反馈提升  
benchmark  
performance。

为了检验公开专家评审数据能否作为“科研品味”的离线代理，我们又加入了一个  
expert-review  
taste-prior  
probe。脚本  
run\_expert\_review\_taste\_prior\_probe.py  
先检查  
Hugging  
Face  
Dataset  
Viewer  
中  
nhop/OpenReview  
的可用性，再使用  
streaming  
方式抽样，因此不需要下载完整数据集。当前运行中，dataset  
statistics  
显示该  
split  
有  
34,638  
行，streaming  
sample  
取  
160  
篇论文；必需字段可用，包括  
title、abstract、reviews、decision、mean\_score、mean\_novelty、mean\_clarity、mean\_impact  
和  
mean\_reproducibility  
等。在  
160  
条样本中，mean\_score  
覆盖  
160  
条、均值  
0.5349；mean\_novelty  
覆盖  
27  
条、均值  
0.6284；mean\_correctness  
覆盖  
106  
条、均值  
0.6267；mean\_clarity  
覆盖  
71  
条、均值  
0.5968；mean\_impact  
覆盖  
73  
条、均值  
0.5459；mean\_confidence  
覆盖  
158  
条、均值  
0.6373。样本中没有可用的  
mean\_reproducibility，这是构建  
reproducibility score

这个定位使

OpenReview

数据可以服务于本文最重要的工作流设计问题。我们不把该数据集当作“在线人类

co-pilot

已经发生”的证据，而是把它作为

participation-mode

selection

benchmark：不同

workflow

variants

可以分别生成假设、实验计划、证据摘要或稿件修订，然后用

OpenReview-derived

rubric

检查这些

artifact

是否更接近高分专家评审论文的特征，例如

novelty、correctness、clarity、impact

和

reviewer

confidence。这样，本文就可以在同一个离线专家评价代理下比较不同人类参与模式：无

human

gate、上游

taste-prior

gate、evaluator-stress

gate、structured-feedback

gate

和

claim-calibration

gate。这个结果不能证明真实同行评审一定接收，但可以在更大规模在线研究数据出现之前，为选择相对更优的人机协作

workflow

提供实验数据支撑。

随后我们把这个想法实际跑成了

participation-mode

selection

experiment。脚本

run\_participation\_mode\_selection\_probe.py

让同一个模型为五种模式生成同任务

artifact：no

human

gate、taste-prior

gate、evaluator-stress

gate、structured-feedback

gate

和

claim-calibration

gate；评分调用则使用

expert-review

probe

中的

OpenReview

高分/低分样例作为

rubric

上下文。当前运行中，no-gate

artifact

overall

为

2, taste-prior

为

3, evaluator-stress

为

4, structured-feedback

和

claim-calibration

都为

5。评分结果在

best\_mode

字段和

ranking

顺序上有一个小的不一致，因此本文不把它解读为唯一胜者，而是把

structured-feedback

与

claim-calibration

视为当前

top

pair。这个结果的设计意义是清楚的：真实评审风格信号最直接有用的位置，是改善稿件结构和削弱未被证据支持的主张；上游

taste-prior

仍然重要，但在这个

artifact-level

probe

中证据还不如后期结构化反馈和主张校准直接。



为了让“人类评审意见就是  
taste/insight”不只停留在概念层面，我们又运行了  
OpenReview-guided  
regeneration  
probe。脚本  
run\_openreview\_guided\_regeneration\_probe.py  
会为每篇论文生成两个  
mini-paper  
artifact：baseline  
只使用  
title  
和  
abstract；review-guided  
版本使用  
title、abstract  
加真实  
OpenReview  
review  
snippets  
和  
decision  
text。初始  
probe  
选择  
3  
篇适合  
AI/ML  
skill  
的论文：一篇  
LLM  
refusal/RLKF  
论文、一篇  
in-context  
learning  
论文，以及一篇  
semi-supervised/robust  
learning  
by  
mixup  
论文；固定模型评分器在  
3/3  
个  
pair  
中都偏好  
review-guided  
artifact。随后我们扩展到  
6  
篇论文，覆盖  
LLM  
reliability、graph  
generation、unlearning/privacy、in-context  
learning、semi-supervised  
robustness  
和  
safety-critical  
causal  
generation，并同时包含

最后, run\_review\_insight\_taxonomy\_probe.py  
从  
32  
条  
OpenReview  
review  
cases  
中归纳哪些评审意见最适合作为自动科研控制信号。模型路由  
taxonomy  
把  
novelty  
concerns  
与  
limitations/weaknesses  
标为高  
actionability (5/5), 分别主要映射到  
scientific-taste-prior  
gate  
和  
claim-calibration  
gate ; clarity  
issues  
的  
actionability  
为  
4/5, 映射到  
structured  
feedback ; metric/evaluation  
issues  
的  
actionability  
为  
4/5, 映射到  
evaluator-stress  
gate。这个  
taxonomy  
使  
IGRE  
的人类  
taste/insight  
更具体：真正有用的评审意见，是能改变  
agent  
该追踪什么问题、该补什么证据、该削弱哪些主张，以及该如何更清楚呈现研究贡献的意见。

为了把这个小样本

taxonomy

扩展成更可复现的信号图谱，我们又运行了

run\_review\_utility\_map\_probe.py。该脚本在

160

篇

OpenReview

样本上抽取

473

条

review

snippets，并用确定性规则判断每类评审意见能否路由到具体

IGRE

gate。结果显示，398

条

snippet

至少包含一个可行动信号，64

条包含低行动性的噪声信号。最强的

gate

pressure

不是泛泛的赞同或反对：245

条触发

evaluator-stress

testing，210

条触发

structured

feedback，140

条触发

claim

calibration，111

条触发

scientific-taste

prior。最高效用类别包括

evaluation/metric

concerns（205

条）、limitations

and

claim-boundary

issues（140

条）、novelty/positioning

issues（111

条）、actionable

suggestions（111

条）、reproducibility

details（79

条）、method-correctness

issues（71

条）以及

clarity/presentation

issues（86

条）。这进一步支持本文的核心工作流主张：真正有用的人类

taste

和

insight，不是所有人类评论，而是那些能改变搜索方向、evaluator

设计、稿件结构或主张边界的评审信号；泛泛表扬和模糊反应只有在被拆解为这些可行动控制信号之后才有价值。

4.  
Benchmark  
选择与评估计划

我们计划比较六种系统版本：完全自动  
baseline、仅创意节点介入、仅分支节点介入、仅评估器节点介入、仅论文主张审计介入，以及完整  
co-pilot  
v3。Benchmark  
不应只局限于  
FML-bench，而应根据论文主张分层选择。对于  
AI  
Scientist-v2  
风格的实验搜索，FML-bench  
是近期最合适的载体，因为它已经能在  
Ubuntu  
环境中跑通，并且能产生分支级日志。对于机器可评分的算法子问题，我们使用  
OpenEvolve-controlled  
tasks，例如函数最小化、0/1  
knapsack  
启发式搜索和加权  
Max-Cut。对于  
FML-bench  
之外的更广泛证据，本文已加入一个  
MLAgentBench  
vectorization  
小实验来测试端到端  
ML  
实验能力，并进一步加入了已打分的官方  
MLAgentBench  
非  
FML  
任务。通过预缓存官方  
CIFAR10  
数据包，MLAgentBench  
CIFAR10/debug  
starter  
baseline  
的官方分数为  
0.5103，co-pilot-selected  
分支在同一官方  
evaluator  
下首个  
seed  
达到  
0.7782；随后相同分支的两个追加  
seed  
得到  
0.7709  
和  
0.7738，三个  
seed  
的  
mean  
score  
为  
0.7743，min  
score  
为  
0.7709，sample  
std  
为

指标包括任务分数、论文质量、主张支持率、搜索效率、人类注意力成本和假设多样性。对于程序化搜索模块，关键消融是：在相同 evaluator 和迭代预算下，比较 OpenEvolve 与直接重复 LLM 代码编辑。因此，FML-bench 应被理解为当前证据来源之一，而不是整个项目的完整 benchmark 定义。

因为 IGRE 的核心贡献是科研品味，而不是普通审批，本文在评估包中加入 taste/insight rubric。该 rubric 从 1 到 5 记录 problem depth、novelty potential、mechanistic value、failure informativeness、benchmark taste、claim significance 和 risk asymmetry，并要求写下简短理由。它刻意不被当作 reward model，而是记录导致人类保留、改写或剪枝某个分支的非指标先验。后续评估应同时报告平均任务表现和高尾部信号：例如一个 autonomous policy 本来会剪掉、但人类保留的分支，是否最终带来更强主张、更好 evaluator 或更有信息量的负结果。

我们也对  
gate  
records  
加入  
taste/insight  
coverage  
audit。因为本文的核心主张涉及人类科研品味，而不是普通  
human  
approval，所以仅靠公开  
human-AI  
interaction  
数据并不够。我们检查了若干相邻公开数据集：CoAuthor  
记录人类与  
GPT-3  
协作写作，CUPID  
记录多轮偏好交互，neulab/agent-data-collection  
汇总多类  
agent  
trajectories，WebChain  
记录  
human-annotated  
web  
trajectories；但这些数据都没有直接覆盖“人类科学家在  
AI  
Scientist-v2  
风格假设—实验—论文循环中介入，并连接到  
benchmark、代码  
artifact、claim  
audit  
和  
manuscript”的场景。因此本文把作者自己的  
Codex  
使用记录构造一个脱敏的  
single-author  
longitudinal  
co-pilot  
trace  
corpus，只发布派生元数据层：gate  
records、artifact  
paths、commit  
IDs、benchmark  
metrics、manuscript  
revisions  
和  
claim-audit  
outcomes，而不公开原始聊天记录或密钥。当前派生快照包含  
52  
条  
gate  
records、35  
条带  
attention-cost  
字段的记录、10  
条带  
taste/insight  
字段的记录、4  
个

根据最新  
paper-quality  
review  
的意见，我们把人类注意力成本从口头指标变成了可审计  
artifact。human-gate  
schema  
现在包含可选的  
attention\_cost  
对象，用于记录  
active  
review  
minutes、wall-clock  
latency、reviewed  
options、reviewed  
artifacts  
和  
decision  
count。我们还对现有  
39  
个  
gate  
records  
做了严格  
coverage  
audit：其中包括  
9  
个  
standalone  
human-gate  
logs，以及  
6  
个  
trajectory  
artifacts  
中的  
30  
个  
embedded  
gates。结果是：当前只有  
1  
条完整  
attention-cost  
记录，即本轮  
Codex  
论文开发中  
operator-recorded  
的  
measurement-readiness  
gate，记录了  
8.5  
分钟  
active  
review、9.67  
分钟  
wall-clock  
latency、3  
个



为了让这一原则可以执行，我们维护了一份

benchmark-to-claim

matrix。

FML-bench

Causality

支持

branch-gate

可行性主张，但还不能证明人类

gate

整体优于

autonomous

baseline。FML-bench

Fairness

支持

evaluator

gate

的必要性，因为可执行性修复和退化预测器暴露了单指标投机风险。OpenEvolve

函数最小化、knapsack、Max-Cut、MLAgentBench

vectorization

和

sklearn

diabetes

probe

分别从不同子问题类型检验

program-search

escalation

policy。ScienceAgentBench、MLE-bench

Lite、PaperBench

和

AIRS-Bench

仍是下一阶段扩展目标，而不是当前已打分主张。因此，后续实验应按“最弱且尚未被支持的主张”来选择，而不是按哪个

benchmark

最方便来选择。

###

4.1

初步程序化搜索

smoke

test

作为可行性检查，我们已经在  
SSH  
控制的  
Ubuntu  
主机上运行了  
OpenEvolve  
0.2.27，并通过  
OpenAI-compatible  
API  
调用  
DeepSeek。任务是一个小型函数最小化  
evaluator，初始程序为随机搜索。一次  
OpenEvolve  
迭代后，系统将  
evaluator  
分数从  
0.0345  
提高到  
0.0378，并保存了一个模拟退火风格的  
evolved  
program。这个结果只是  
smoke  
test：它证明远程  
OpenEvolve  
路径、evaluator  
加载、模型路由、checkpoint  
和  
artifact  
捕获可以跑通，但还不能证明本文核心主张，即  
human-gated  
research  
能提升最终论文质量。

我们还在相同  
DeepSeek  
模型、相同初始程序和相同  
evaluator  
下运行了  
direct  
one-shot  
LLM-edit  
baseline。该直接编辑基线得分为  
0.038021，略高于一次迭代  
OpenEvolve  
的  
0.037816，也略高于五次迭代  
OpenEvolve  
的  
0.038007。这个边界结果支持  
Co-Pilot  
AI  
Scientist  
v3  
的一个核心设计：程序化搜索不应该默认总是启动，而应该由明确的升级  
gate  
控制。对于极小预算或简单局部改写，直接编辑可能已经足够；当搜索空间更丰富、预算更大时，OpenEvol  
ve  
风格的种群搜索才更可能发挥价值。

为了测试后一种情况，我们进一步加入了一个更复杂的  
0/1  
knapsack  
启发式任务。初始  
value/weight  
贪心程序在  
18  
个确定性实例上的平均最优比为  
0.991519。direct  
LLM  
rewrite  
将分数提升到  
0.995270。五次迭代  
OpenEvolve  
进一步提升到  
0.999439，且没有非法实例。进化出的程序加入了局部改进：移除一个或两个已选物品后，再用贪心方式重  
新填充容量。这个结果为升级  
gate  
提供了正例：当子问题具有更丰富的组合结构，并且存在自动  
evaluator  
时，OpenEvolve-style  
search  
确实可能优于直接编辑。

为了避免只依赖一个手工

knapsack

结果，我们又加入了第二个受控组合优化任务：加权

Max-Cut。初始程序交替分配节点，在

16

个确定性图实例上相对于多起点局部搜索

reference

的归一化得分为

0.734680。一次

direct

DeepSeek

rewrite

将得分提升到

0.962237。使用相同模型和

evaluator

的五次迭代

OpenEvolve

run

达到

0.970833，比

direct

rewrite

高

0.008596，且没有非法实例。这个优势很小，而且只有一个

seed，但它给出了第二个算法子问题正例。结合函数最小化任务中的负边界结果，这更支持

selective

program-search

gate，而不是无条件启动

OpenEvolve。

###

4.2

AI

Scientist-v2

分支

gate

回放分析

我们还对已有的两个  
AI  
Scientist-v2/FML-bench  
smoke  
run  
做了回放分析。在  
Causality\_causalm1  
任务中，第一个  
draft  
就取得了四步运行中的最佳验证  
MAE：0.598943，而原始  
baseline  
为  
1.296259；第二个  
draft  
和后续  
refinement  
都没有超过它。如果在两个  
draft  
之后加入  
branch  
gate，人类会保留第一条分支，并避免至少一次低价值后续尝试。在  
Fairness\_fairlearn  
任务中，第一个  
draft  
反而让公平性指标比  
baseline  
更差：0.316467  
对比  
baseline  
0.186632；第二次尝试因为  
Fairlearn  
兼容性问题失败，后续尝试也要么更差、要么出错。此时  
human  
branch  
gate  
应暂停该分支，并把系统路由到  
evaluator/兼容性修复或新的公平策略。这个回放证据还不能替代在线  
human-gated  
benchmark，但它说明  
AI  
Scientist-v2  
的日志轨迹中已经存在适合人类  
co-pilot  
介入的可操作检查点。

###

4.3

在线

AI

Scientist-v2

分支

gate

小实验

为了从回放证据推进到在线证据，我们在

Ubuntu

主机上新跑了一次

FML-bench

小实验。任务仍为

Causality\_causalm1。我们把

AI

Scientist-v2

设置为两步预算、两个

draft

idea、两个模拟并行

worker，并用临时

agent

配置把全部预算放到第一阶段，从而强制产生两个可比较的

draft

分支。第一个

draft

的验证

MAE

为

1.149610，第二个

draft

的验证

MAE

为

0.621262；该任务中

MAE

越低越好。因此，结构化

branch

gate

选择第二个

draft，并剪枝第一个

draft。benchmark

自动对最佳验证分支做最终测试，得到

test

MAE

0.640451。

这个在线小实验说明，本文提出的

branch

gate

可以插入真实

AI

Scientist-v2

决策前沿，并基于日志指标和代码快照做出清晰的预算分配决策。它还不能证明

human

gating

优于完全自动

AI

Scientist-v2：该实验尚未从被选中的分支继续

resume

进行后续

human-gated

search，而且其测试分数略弱于之前的四步

autonomous

smoke

run。因此，我们把它定位为在线人类介入可行性证据，而不是系统级优势的最终证据。

随后，我们实现了一个最小  
selected-branch  
continuation  
runner。该  
runner  
会把人类  
gate  
选中的代码快照临时写回官方  
FML-bench  
任务模板，从该状态启动一个短预算  
AI  
Scientist-v2  
continuation  
run，并在结束后恢复模板文件。从被选中的第二个  
draft  
出发，继续两步后验证  
MAE  
达到  
0.401240， test  
MAE  
达到  
0.402170。这个结果优于  
live  
two-draft  
gate  
run  
的  
test  
MAE  
0.640451，也优于早期四步  
autonomous  
smoke  
run  
的  
test  
MAE  
0.617719。这个比较仍然是初步的：当前  
continuation  
是通过  
snapshot  
seeding  
实现的，还没有保存原始内存中的  
tree  
对象；同时它只覆盖一个小任务和一个  
seed。因此，我们只把它作为“branch  
gate  
->  
selected  
snapshot  
->  
additional  
AI  
Scientist-v2  
budget”这条路径可以执行的证据，而不是最终统计结论。



根据  
paper-quality  
review  
的意见，我们又补了更接近同预算的  
autonomous  
baseline。第一组  
matched  
run  
使用同一个  
Causality\_causalml  
任务、同一个  
DeepSeek  
模型、两个初始  
idea、两个并行分支和四个  
AI  
Scientist-v2  
总步数，但不进行人类分支选择。它得到验证  
MAE  
0.389451、test  
MAE  
0.421474。在这一组中，human-gated  
路径在  
held-out  
test  
MAE  
上略好：0.402170  
对比  
0.421474；但  
autonomous  
baseline  
在验证  
MAE  
上略好。

随后我们又跑了第二组  
matched  
Causality  
replicate。human-gated  
两  
draft  
frontier  
选择了验证  
MAE  
0.605881、test  
MAE  
0.646224  
的分支；snapshot-seeded  
continuation  
没有进一步改善  
held-out  
test, 最终验证  
MAE  
为  
0.627837、test  
MAE  
为  
0.646224。对应的四步  
autonomous  
baseline  
得到验证  
MAE  
0.537972、test  
MAE  
0.595685。在第二组中, autonomous  
路径在验证集和  
held-out  
test  
上都更好。

因此，两组同预算对照的结论是

mixed

evidence：一组

held-out

test

支持

human-gated

continuation，另一组支持

autonomous

baseline。两组平均后，human-gated

test

MAE

为

0.524197，autonomous

test

MAE

为

0.508579；由于该指标越低越好，均值反而略支持

autonomous

baseline。这个结果消除了一个重要的计算预算混淆因素，但不支持“人类

gate

普遍优越”的宽泛结论；它只支持

branch

gate

可以插入、selected

snapshot

可以继续搜索这一可行性主张。

我们现在还用脚本生成这组  
FML  
matched-comparison  
aggregate，而不只依赖手写表格。生成的  
audit  
显示：两组正式  
pair  
中，human-gated  
胜  
1  
次，autonomous/tie  
胜  
1  
次；autonomous-minus-human  
的平均  
delta  
为  
-0.015618，delta  
SEM  
为  
0.034921，并显式标注  
statistical  
claim  
为  
not\_supported\_n\_too\_small。单独的  
online-smoke  
comparison  
对  
co-pilot  
performance  
也是负结果：test  
MAE  
为  
0.862015  
对  
0.428516。因此，这份脚本化  
summary  
是当前  
FML  
performance  
evidence  
的权威汇总。

在第二个  
Causality  
prospective  
package  
之后，我们又把同一个  
package  
runner  
扩展到  
ubuntu-heshi  
上另一个实际可用的  
FML-bench  
workspace：Fairness\_fairlearn。这个结果  
同样不是  
co-pilot  
的正结果，但失败方式不同：co-pilot  
branch  
frontier  
的两个候选都没有通过  
validation，因此记录的  
frontier  
gate  
选择  
abort\_no\_valid\_branch，而不是强行继续一个无效分支。  
匹配的  
autonomous  
run  
成功完成，test  
primary  
metric  
为  
0.172152  
(abs\_demographic\_parity\_diff\_mean，越低越好)。当前  
prospective  
package  
audit  
因此覆盖  
4  
个  
通过格式审计的  
package：1  
个受控  
micro-task  
正结果、2  
个  
Causality  
FML  
负结果，以及  
1  
个  
Fairness  
FML  
无有效  
continuation  
的失败案例；四个  
package  
都包含完整的  
attention\_cost

###  
4.4  
非  
FML  
benchmark  
与程序搜索小实验  
根据上面的  
benchmark  
选择原则，我们还把  
MLAgentBench  
作为非  
FML  
评估来源。我们在  
Ubuntu  
主机上克隆  
MLAgentBench，并先运行其轻量  
vectorization  
任务，使用内置  
Agent  
baseline。该  
baseline  
只执行  
starter  
train.py  
并提交结果。官方  
baseline  
成功完成，final  
score  
为  
3.172504  
秒，total  
benchmark  
time  
为  
3.365531  
秒，且没有错误标记。

随后，我们把同一个任务封装成更严格的本地 evaluator：在接受运行时间之前， evaluator 会用一个小型确定性输入，把候选 Conv2DLayer.forward 的输出和 nested-loop reference 做数值比对。在这个受控 evaluator 下， starter program 的 median runtime 为 3.261186 秒。一次 direct DeepSeek deepseek-chat rewrite 生成了看似合理的向量化代码，但因为数值不一致没有通过 correctness gate。相反，使用同一 DeepSeek 模型的三轮 OpenEvolve-style run 在第 1 轮找到了正确候选， median runtime 为 0.051882 秒，相比受控 starter program 约快 62.86 倍。这个结果支持一个较窄但重要的结论： program-search-escalation 节点可以在 FML-bench 之外的机器可评分子问题上发挥作用。但它还不能证明完整 co-pilot 架构能提升整篇论文质量。

为了检查稳健性，我们又用更多

random

seed

重复同样的三轮

OpenEvolve

设置。在

seed

0、1、2、3、4、7、42、123

共八次运行中，所有运行都保留了正确

best

program，并且都比受控

starter

更快。八个

seed

的

best

runtime

中位数为

0.024581

秒，相当于相对

starter

约

132.67

倍的中位加速；其中

6

个

seed

找到低于

0.1

秒的程序。这个结果明显强于最初的三

seed

probe，但仍不是确定性成功：seed

7

只有约

1.09

倍加速，seed

1

约

15.57

倍加速。因此，该结果增强了“程序搜索模块可以找到有效代码变换”的证据，同时保留了极小预算下

seed/budget

sensitivity

的重要

caveat。



为了避免非  
FML  
证据只覆盖底层  
runtime  
optimization，我们又加入了一个使用  
sklearn  
内置  
diabetes  
regression  
dataset  
的受控  
tabular  
modeling  
probe。这个  
probe  
不需要  
Kaggle  
凭证，也不应被报告为官方  
MLAgentBench  
分数。初始程序是刻意粗糙的均值预测器，在五个确定性  
split  
上  
mean  
RMSE  
为  
78.572189。一次  
direct  
DeepSeek  
rewrite  
找回了标准  
Ridge  
风格  
baseline，mean  
RMSE  
为  
55.895460。三个三轮  
OpenEvolve  
seed  
也都明显优于均值预测器，best  
RMSE  
分别为  
55.895460、55.946535  
和  
55.895460；其中位  
RMSE  
为  
55.895460，基本与  
direct  
rewrite  
持平。这个结果把  
benchmark  
覆盖扩展到了表格建模子问题，同时也给出了重要边界条件：当改进只是一个标准的小型建模修改时，direc  
t  
editing  
可以和  
program  
search

我们还运行了若干  
benchmark  
扩展  
probe。其中最强的一项升级是官方  
MLAgentBench  
CIFAR10/debug  
任务。该  
setup  
probe  
先修复了远端环境缺少  
torchvision  
的问题，并安装了与本地  
torch  
匹配的  
CPU  
wheel；在预缓存官方  
170  
MB  
CIFAR10  
压缩包后，官方  
starter  
run  
完成并得到分数  
0.5103。co-pilot-selected  
分支使用带  
batch  
normalization  
的小型  
CNN、数据增强、AdamW、cosine  
learning  
rate、label  
smoothing  
和  
8  
个训练  
epoch，在同一官方  
evaluator  
下首个  
seed  
达到分数  
0.7782。相同分支的两个追加  
seed  
达到  
0.7709  
和  
0.7738，三个  
seed  
的  
mean  
score  
为  
0.7743，min  
score  
为  
0.7709，sample  
std  
为

###

4.5

主张审计

在完成这些  
pilot  
实验后，我们做了一次  
claim-evidence  
audit。通过  
Monica  
路由的  
gpt-4o-mini  
审稿式检查认为：本文的架构贡献是合理的，但当前实验证据还不足以支持“人类  
gate  
提高论文质量”或“完整  
co-pilot  
系统优于  
autonomous  
AI  
Scientist-v2”这类宽泛结论。因此，本文把这些表述保留为  
evaluation  
protocol  
要检验的假设，而不是已经证明的结论。当前  
audit  
只支持较窄的实证主张：OpenEvolve-style  
search  
可以在部分机器可评分子问题上有效，但在极小预算下存在  
seed  
sensitivity；direct  
editing  
在简单  
tabular  
modeling  
probe  
上可以匹配  
OpenEvolve；branch  
gate  
可以插入  
AI  
Scientist-v2  
风格日志轨迹；evaluator  
gate  
必须在  
continuation  
前拒绝无法执行以及指标投机的分支；两组  
matched  
Causality  
对照给出的是混合证据，而不是稳定的人类  
gate  
优势。第一次把  
online  
branch  
gate  
扩展到  
Fairness\_fairlearn  
时，两条候选都在  
validation  
阶段失败，因此本文只把它作为  
failure-mode  
evidence  
归咎，而不计入

在加入  
prospective  
matched-budget  
指标汇总后，我们又通过  
Monica  
路由刷新了两次  
paper-quality  
review。gpt-4o-mini  
给出  
weak-accept  
建议，认为新颖性和可复现性较强，但严谨性和证据仍只有中等水平。claude-3-7-sonnet-latest  
更严格，认为如果目标是强  
ML/NLP  
systems  
venue，当前版本应被拒，因为核心  
human-gating  
和  
paper-quality  
主张仍未被证明，最强的  
FML-bench  
prospective  
package  
对  
co-pilot  
performance  
是负结果，而且系统仍缺少  
same-continuous-trajectory  
的  
paper-generating  
对照。两个模型的共同结论是：下一版必须在更多任务和随机种子上比较  
autonomous  
AI  
Scientist-v2  
与  
human-gated  
variants，记录人类注意力成本，并更清楚地区分已经完成的系统证据和  
future  
work。

5.

## 当前贡献与尚未证明的主张

本文当前贡献包括：

1. 一个面向协作式自动科研的模块化架构。
2. 一个用于科研  
agent  
的人类参与节点形式化  
schema。

3.  
一条  
live  
Monica-routed  
hypothesis-frontier  
smoke, 生成  
4  
个新  
research-frontier  
candidates, 进行  
critique/ranking, 并选择  
frontier\_004  
作为可能的下一预算评估方向。

4.  
一个  
same-model  
autonomous  
hypothesis-front-end  
baseline  
probe, 比较已归档  
IGRE  
frontier  
portfolio  
与  
autonomous  
AI  
Scientist-v2-style  
portfolio, 并把  
IGRE  
评为  
4、autonomous  
评为  
3, 但只作为前端  
planning  
evidence。

5. 一个基于  
Hugging  
Face  
nhop/OpenReview  
的  
offline  
expert-review  
taste-prior  
data  
probe, 通过  
streaming  
方式从  
34,638  
行专家评审数据中抽样  
160  
行, 证明它可以支持有限的科研品味先验实验。
6. 一个  
participation-mode  
selection  
probe, 使用  
OpenReview-conditioned  
scoring  
比较  
no-gate、taste-prior、evaluator-stress、structured-feedback  
和  
claim-calibration  
五种模式, 当前把  
structured-feedback  
与  
claim-calibration  
识别为  
top  
pair。

7.  
一个  
OpenReview-guided  
regeneration  
probe：初始  
3  
篇运行中  
review-guided  
版本  
3/3  
胜出，扩展  
6  
篇运行中在生成模型评分器下  
5/6  
胜出；更严格的  
Claude  
跨模型复评给出  
review-guided  
3/6  
胜、baseline  
1/6  
胜、2  
个  
tie。



- 8.
- 一个
  - review-insight
  - taxonomy
  - probe
  - 和一个
  - deterministic
  - review-utility
  - map：前者从
  - 32
  - 条
  - OpenReview
  - review
  - cases
  - 中归纳评审意见类型，后者在
  - 160
  - 篇论文的
  - 473
  - 条
  - review
  - snippets
  - 上统计哪些评论真正可行动；二者共同把
  - novelty、evaluation、claim-boundary、clarity、reproducibility
  - 和
  - correctness
  - signals
  - 映射到
  - IGRE
  - gates，并区分
  - actionable
  - review
  - insight
  - 与泛泛表扬或模糊反应。
- 9.
- 一个
  - same-manuscript
  - structured-feedback
  - probe，将
  - frontier\_004
  - 操作化，并通过两版修订与固定
  - rubric
  - 模型评分比较
  - informal
  - feedback
  - 和
  - IGRE-structured
  - feedback。

10.
  - 一条
  - retrospective
  - full-gate
  - trajectory, 展示
  - idea、evaluator、branch、program-search
  - 和
  - claim-audit
  - gate
  - 都可以用同一
  - schema
  - 记录。
11.
  - 一个可重新运行的
  - full-gate
  - trace
  - 脚本, 可以从已归档实验摘要中重新计算
  - gate
  - chain, 并明确把输出标记为
  - artifact
  - replay。
12.
  - 第一条
  - online
  - full-gate
  - smoke
  - trajectory, 在一次远端运行中覆盖
  - idea、evaluator、branch、program-search
  - 和
  - claim
  - gate, 同时记录了负向
  - continuation
  - 结果。
13.
  - 一个同时评估平均
  - benchmark
  - 表现和人类参与下高尾部科研上限的实验协议。
14.
  - 远程
  - OpenEvolve
  - 与
  - FML-bench
  - 小实验, 证明可验证微演化和前沿转向两个
  - IGRE
  - 算子可以在
  - Ubuntu
  - 主机上运行。

15.
  - 两组同预算
  - FML-bench
  - Causality
  - 对照：human-gated
  - branch
  - continuation
  - 与四步
  - autonomous
  - AI
  - Scientist-v2
  - baseline，结果呈混合状态。
16.
  - 第一条
  - online
  - full-gate
  - smoke
  - 的同
  - FML
  - step
  - autonomous
  - baseline，显示
  - human-gated
  - continuation
  - 在该
  - smoke
  - 对照中表现更差。
17.
  - 两个非
  - FML
  - 程序搜索小实验，分别覆盖
  - runtime
  - optimization
  - 和
  - tabular
  - regression，用于扩展
  - FML-bench
  - 之外的
  - benchmark
  - 覆盖面。
18.
  - 一个可在
  - Codex
  - 中复用的
  - workflow
  - skill。
19.
  - 中英文论文、使用文档和主张审计
  - artifact，便于复现和传播。

20.  
Monica  
路由的  
paper-quality  
review  
artifact, 用于记录下一轮修改前的外部模型批评。

21.  
human-gate  
attention-cost  
audit, 显示  
39  
条被审计  
gate  
中已有  
1  
条完整  
operator-recorded  
attention-cost  
记录, 另外  
38  
条仍不完整; 未来  
prospective  
experiment  
gate  
必须补齐这些字段后, 才能提出  
attention-efficiency  
claim。

22.  
taste/insight  
coverage  
audit, 显示当前已有  
2  
条完整  
scientific-taste  
prior  
记录, 另有  
37  
条  
gate  
仍缺少完整  
taste/insight  
字段。

23.  
prospective  
matched-budget  
package  
validator, 用来定义在声称论文质量提升、人类注意力效率提升或优于  
autonomous  
AI  
Scientist-v2  
之前, 最低限度需要具备的非  
synthetic  
证据形状。

24.  
一个  
controlled  
prospective  
Max-Cut  
micro-pilot  
package, 已经通过该  
validator, 并包含完整  
attention/taste  
logging、matched  
baseline  
metrics、claim  
audit  
和同次运行生成的  
manuscript  
artifact。

25.  
一个  
prospective  
FML-bench  
Causality  
package, 包含完整  
attention/taste  
logging  
和  
matched  
autonomous  
baseline; 在这个两步小预算设置中, co-pilot  
test  
MAE  
为  
0.646224, autonomous  
baseline  
为  
0.624703, 因此是负向  
co-pilot  
performance  
结果。

26.

一个

prospective

package

指标汇总表, 把通过

audit

的

package

按任务、指标方向、co-pilot

分数、autonomous

分数和

claim

implication

汇总; 当前结果是

1

个

controlled

micro-task

正向结果、2

个

Causality

FML-bench

负向结果, 以及

1

个

Fairness\_fairlearn

无有效

continuation

的失败案例。

27.

一个

matched

mini-manuscript

quality

probe：为同一个

FML

package

生成

autonomous

mini-manuscript, 并让

Monica

路由的

gpt-4o-mini

和

claude-3-7-sonnet-latest

对匿名

A/B

manuscript

评分；两个模型都偏好

co-pilot

package

mini-manuscript, overall

为

4

对

3。

28.

一个

matched

full-manuscript

generation

probe：把同一个已归档

FML

evidence

package

渲染成两篇完整论文形态的

manuscript，并用确定性内部

rubric

评分；最新

Fairness

package

中，co-pilot

manuscript

因结构完整、证据绑定、主张校准和方法区分度得到

4.18

overall, autonomous

manuscript

得到

4.11

overall, 但

autonomous

是唯一拥有有效

FML

标量测试指标的路径。



29.

一个  
repeated  
same-continuous-trajectory  
paired  
online  
full-gate  
manuscript-production  
汇总，覆盖三条  
smoke  
run，其中包括一条  
Fairness\_fairlearn  
no-valid-branch  
failure  
trajectory；有效  
Causality  
benchmark  
汇总为  
0  
次  
co-pilot  
胜、1  
次  
autonomous  
胜、1  
次打平，而  
Monica  
路由模型评审在  
6/6  
次  
reviewer  
call  
中偏好  
co-pilot  
manuscript。

30.

一个  
Human  
Co-Pilot  
Trace  
Dataset  
protocol，把本文实际  
Codex  
使用记录转化为脱敏派生数据集，而不是依赖不匹配的通用  
human-AI  
interaction  
数据集。

当前证据还不能证明人类

gate

能提升论文质量，也不能证明完整

co-pilot

系统优于

autonomous

AI

Scientist-v2。structured-feedback

probe

只是单篇稿件上的

measurement

artifact，不能替代独立专家评审。这些更强主张仍是下一阶段

benchmark

要验证的目标。

6.

局限性

本文不预设人类参与一定有效。人类

gate

可能引入偏见、降低搜索速度、压缩探索多样性；在短预算

benchmark

中，它甚至可能不如完全自动搜索策略。这不是附带

caveat，而是本文方法需要正面评估的一部分。IGRE

把人类科学家视为高方差搜索算子，其价值可能不体现在平均分上，而体现在高尾部：更好的问题品味、更能揭示机制的

evaluator、更尖锐的失败解释，或者愿意追踪一个更冒险但更原创的方向。程序化搜索也可能只优化局部指标，却不能提高论文层面的科学贡献；在极小预算下，它也未必优于直接

LLM

编辑。专家论文评分成本较高，而且不同评审可能存在分歧。因此，第一版实验应保持窄主张，并在

gate

无法改善结果时如实报告负结果。当前

selected-branch

continuation

证据在两组

matched

pair

中呈混合状态，还不是统计受控

benchmark；retrospective

full-gate

trajectory

和

executable

artifact

replay

证明了

schema、决策链和可复现

traversal

logic。online

smoke

trajectory

已经在一次远端运行中覆盖五类

gate，但预算极小、混合了

FML

branch

task

和

knapsack

program-search

子问题，并且

continuation

test

score

变差；同

FML

step

autonomous

baseline

也优于

human-gated

continuation。更强主张需要更多任务、更多随机种子、更丰富的预算分配设置、更大规模在线轨迹、独立论文质量评审，以及能捕捉少数高质量科研结果的指标，而不只是平均任务分数。

当前  
human-gate  
logs  
也缺少可度量的人类注意力成本。我们可以统计决策  
artifact, 但还不能计算  
active  
review  
minutes  
或  
wall-clock  
latency, 因此不能声称  
gate  
提高了单位人类努力产出的科研质量。下一轮  
matched-budget  
实验必须前瞻性记录  
attention  
cost。  
新的  
prospective  
matched-budget  
package  
audit  
现在已经在  
controlled  
micro-pilot、两个  
FML-bench  
Causality  
pilot  
和一个  
FML-bench  
Fairness  
pilot  
上通过。这个进展说明最小证据形状可以被真实远端计算生成和审计, 而且已经延伸到  
AI  
Scientist-v2  
风格  
benchmark ; 但  
FML  
packages  
在当前小预算设置中都是  
co-pilot  
平均性能的负结果或无有效  
continuation  
的失败案例, 且这些  
package  
仍没有独立评价完整论文质量。因此当前论文仍应被限制在  
pilot-system  
evidence, 直到更多任务、更多  
seed、更大预算和独立论文质量评审完成。

我们还新增了  
package  
指标汇总，而不只报告  
artifact  
audit  
是否通过。当前四个  
passing  
package  
中，controlled  
Max-Cut  
micro-task  
的  
human-selected  
branch  
在  
mean  
normalized  
score  
上胜出（0.984419  
对  
0.596214），但这只是微任务；两个  
FML-bench  
Causality  
package  
都由  
autonomous  
baseline  
在  
test  
MAE  
上胜出，分别为  
0.624703  
对  
0.646224，以及  
0.296399  
对  
0.646224；Fairness\_fairlearn  
package  
中  
co-pilot  
frontier  
没有有效测试分数，而  
autonomous  
baseline  
的  
primary  
metric  
为  
0.172152。四个  
human  
gate  
都已经记录完整  
attention-cost  
和  
taste/insight。这个结果正是  
IGRE

我们还补了第一个  
matched  
mini-manuscript  
quality  
probe。该  
probe  
从同一个  
FML  
package  
的  
autonomous  
baseline  
生成一篇  
autonomous  
mini-manuscript，把  
co-pilot  
package  
manuscript  
匿名为  
A，把  
autonomous  
manuscript  
匿名为  
B，并让  
Monica  
路由的  
gpt-4o-mini  
和  
claude-3-7-sonnet-latest  
按  
claim  
calibration、evidence  
use、methodological  
completeness、limitation  
honesty、clarity  
和  
overall  
quality  
评分。两个模型都偏好  
A，overall  
为  
4  
对  
3；理由是  
co-pilot  
mini-manuscript  
虽然  
benchmark  
分数更差，但对主张边界和局限性写得更清楚。这个结果只能说明  
manuscript-quality  
measurement  
pipeline  
可运行，不能证明完整  
co-pilot  
系统已经能写出更好论文。

这次新增的  
full-manuscript  
probe  
只缩小了一个具体缺口，并没有关闭顶会证据缺口。它说明已归档  
FML  
package  
中的结构化证据足以生成两篇完整、主张校准的论文形态  
manuscript；最新  
Fairness  
probe  
中  
co-pilot  
manuscript  
的内部  
rubric  
为  
4.18, autonomous  
manuscript  
为  
4.11, 但  
autonomous  
是唯一拥有有效  
FML  
标量测试指标的路径。更新的  
repeated  
same-continuous  
online  
smoke  
summary  
进一步说明  
fresh  
online  
co-pilot  
trajectory  
可以生成完整论文形态  
artifact，并且可以同轮生成  
autonomous  
manuscript  
comparator；但两条有效  
Causality  
paired  
smoke  
的  
benchmark  
汇总为  
0  
次  
co-pilot  
胜、1  
次  
autonomous  
胜、1  
次打平，mean  
test  
MAE  
为  
co-pilot

taste/insight

证据目前也只是

logging-readiness

阶段。归档中已有

2

条完整

scientific-taste

prior

记录：一条来自作者要求扩展

benchmark

并突出高尾部科研品味的指令，另一条来自本轮

operator-recorded

决策，即优先补

attention/taste

测量，而不是继续堆弱

benchmark

运行。但这两条记录都还不能证明该决策改善了下游科研结果。下一轮实验必须前瞻性记录

taste

rationale，才能检验人类

insight

是否真的改变了科研搜索分布。



作者自己的

Codex

科研轨迹只能作为单作者

ecological/process

case, 数据量和主体多样性都太小, 不应该作为主要实证数据来证明“人类参与自动科研会提升结果”。OpenReview/Hugging

Face

专家评审数据则确实是人类科研

taste

和

insight

的真实文本化数据, 但它是离线、异步的评审数据, 而不是实时

co-pilot

交互轨迹。它可以用于

artifact

regeneration、participation-mode

selection、review-insight

taxonomy

和

review-utility

mapping, 本文新增的四个

OpenReview

probes

就是在做这件事; 但它还不包含人在自动科研过程中实时改变搜索前沿的行为。真正有力的在线

human-guided

automated-science

数据需要一个被大量科研人员长期使用的

skill

或科研

assistant, 在取得同意和脱敏后前瞻性记录人类介入、attention

cost、artifact

links、后续

benchmark

和论文质量结果。现阶段这类数据更可能由主流

agent

公司或大模型平台通过大规模产品化系统收集; 本文只能把它作为重要

future

work, 而不是当前已完成证据。

当前实现现在已有

smoke

级别的

repeated

same-continuous-trajectory

在线论文生成对照，但规模仍不足以支撑

systems

paper

的强主张。下一版

systems

paper

至少需要报告多组更大规模的

matched

在线轨迹，覆盖更多任务和随机种子，从假设生成一直到最终

claim-audited

manuscripts。

7.

结论

Co-Pilot

AI

Scientist

v3

将自动科学发现重新定义为洞察门控科研演化。该系统保留自动

agent

的大规模搜索能力，同时给人类科学家提供明确、可记录、可实验检验的影响节点。它最重要的主张不是“人类总能提高平均

benchmark

表现”，而是人类科研品味和

insight

可以改变搜索分布，使系统更有机会产生少数但更原创、更可能开创新方向的成果。如果未来

matched

benchmark

支持这一高尾部假设，co-pilot

科研系统可能通过改变“系统尝试什么样的科学”来写出更好的论文，而不是简单把人类排除在科学之外。

当前论文应被理解为一个带

pilot

evidence

的可复现系统

proposal，而不是最终优越性证明。