

Co-Pilot AI Scientist v3：面向协作式自动科研的洞察门控科研演化

作者：何石，新加坡国立大学计算机学院

摘要

自动科研智能体已经开始把创意生成、实验执行、benchmark
评估和论文写作连接成闭环。然而，完全自动化的科研流水线仍然难以处理一些关键节点：选择什么问题值得做、如何判断证据强弱、如何解释失败结果、以及哪些结论可以负责任地写进论文。本文提出

Co-Pilot

AI

Scientist

v3

及其核心方法：洞察门控科研演化（Insight-Gated

Research

Evolution,

IGRE）。IGRE

不是把已有科研

agent

直接拼装在一起，而是把其中有用的设计压力重新组织成一个面向高尾部科研产出的过程：自动系统维持广泛、可执行的搜索前沿，人类则在显式

gate

中注入科研品味、风险偏好和主张责任。本文最重要的目标不是证明一个二元命题，即“人类参与是否一定提高论文质量”；而是设计、比较和改进多种人类参与模式，让

AI

难以量化的科研品味和人类

insight

能更好地进入自动科研流程。本文定义一个可复现评估协议，用于比较完全自动、局部

gate

和完整

co-pilot

版本在小型自动科研任务上的表现。核心假设是非对称的：人类参与可能降低短预算

benchmark

的平均表现，但设计良好的人类参与

workflow

可能提高产生高新颖性、高影响力科研结果的概率，而这类高尾部结果才是科学发现中最重要的部分。

1.

引言

自动科研的下一步，不应该只是“无人参与的论文工厂”。科学研究不仅是可执行步骤的串联，也包括选择有价值问题、识别弱证据、重新解释失败、决定哪些主张值得提出。已有系统提供了重要启发：假设辩论、可执行实验搜索、以及自动评估驱动的代码演化。但本文的方法目标不同：科研

co-pilot

不应只最大化短期

benchmark

的平均分，还应提高系统进入质变方向的概率，例如更尖锐的问题、更能揭示机制的 evaluator、更有解释力的失败、或者能打开新研究线索的主张。

本文提出

Co-Pilot

AI

Scientist

v3，并把它形式化为洞察门控科研演化。目标不是用随意审批拖慢自动流水线，而是把人类介入视为一种稀缺、高方差的搜索算子，只在科研判断能改变搜索前沿形状的位置触发。本文定义五类

gate：科研品味先验、评估器压力测试、前沿转向、可验证微演化，以及主张校准。

因此，本文真正要回答的是一个 workflow 设计问题：哪一种人类参与模式最能把科研品味转化为有用的搜索压力？IGRE

不假设人类只有一种角色，而是比较上游

taste-prior

selection、evaluator

stress

testing、中途

frontier

steering、选择性

program-search

escalation、针对证据稿件的

structured

feedback，以及最终

claim

calibration

等多种模式。当前实验的作用是用数据塑造这些模式、找出更合适的参与节点和边界条件，包括短预算下完全自动搜索反而更强的负例。这样，本文的实际意义是为自动科研设计更有效的人机协作

workflow，而不是简单判断人类和

AI

谁整体更强。

2.

相关工作

AI

Co-Scientist

将科学发现建模为假设生成、讨论和演化，优势在于研究早期的想象力和证据组织。AI

Scientist-v2

通过

agentic

tree

search

将候选想法转化为可运行实验和论文。AlphaEvolve

使用自动评估驱动代码进化，适合机器可评分问题。FunSearch

是

LLM

引导程序搜索用于数学发现的早期代表。Coscientist

则展示了

LLM

agent

如何连接化学工具和实验自动化。

IGRE

借鉴这些系统带来的设计压力，但不照搬它们的控制逻辑。它从假设生成系统中吸收多样化

conjecture

的需求，但把自由辩论改造成可记录的科研品味先验；它从自动论文系统中吸收可执行实验搜索，但在

benchmark

分数不足以决定方向的地方加入前沿转向和主张校准；它从程序演化系统中吸收机器可评分子问题的深度搜索，但通过选择性升级

gate

控制成本和适用范围。因此，本文优化的不是单个任务指标，而是一条证据对齐、上限更高的科研轨迹。

###

2.1

与一般科研

co-pilot

的区别

很多

co-pilot

系统把人类看作审批者、提示词编写者、偏好标注者或异常兜底者。IGRE

的算法主张不同：人类对自动科研最重要的贡献，往往是对“什么样的科研值得做”的非指标化先验，也就是科研品味。这种先验很难压缩成单一

reward。它包括：一个问题是否有深度，一个负结果是否揭示机制，一个

benchmark

是否太容易被投机，一个看似当前分数不高的分支是否值得保留，以及一个主指标只小幅提升的结果是否仍然值得写成论文主张。

因此，IGRE

区分了三种在人机协作

agent

中经常被混在一起的角色。偏好是在人类已经看到若干完成选项后选择更喜欢的一个；监督是阻止无效或不安全行为；科研品味则是在结果尚未显现之前改变系统应该搜索什么。第三种才是本文的核心区别。IGRE

不把

taste

强行拟合成完整

reward

model，而是把它记录为结构化、可审计、但保留部分定性判断的

gate

record，用它改变搜索前沿。这样，系统可以诚实评估人类输入：它可能降低平均分，但应该被检验的是它是否提高了少数开创性科研轨迹出现的概率。

3.

方法

Co-Pilot

AI

Scientist

v3

实现的是洞察门控科研演化。IGRE

包含四个机器循环和五个面向人类的算子。机器循环保留自动科研的规模化能力：假设扩展、实验构造、可执行前沿搜索和可验证微演化。人类算子则放在科研品味可能改变“哪些前沿值得继续展开”的位置。

- 3. evaluator baseline
- 4. evaluator_stress_test
- 5. B
- 6. frontier_steering
- 7. evaluator
- 8. verifiable_micro_evolution
- claim_calibration
- gate

每一次人类介入都被记录为结构化数据，包括决策类型、候选选项、理由、影响到的产物和后续结果。这样，人类参与不是隐藏的旁路，而是可复现记录的一部分。

当前

artifact

package

还加入了一条

retrospective

full-gate

trajectory，覆盖本文提出的全部

gate

类型。它把选择窄版

human-gated

tree-search

贡献的

idea

gate、拒绝公平性指标投机分支的

evaluator

gate、在两个

Causality

draft

中选择较优分支的

live

branch

gate、升级到

OpenEvolve

的

program-search

gate，以及把未被证实的优越性主张降级为

future

work

的

claim

gate

串成一条可审计链条。这个轨迹证明了日志格式和证据链可以成立，但还不是一次所有

gate

都在线连续运行的端到端实验。

此外，本文还提供了一个可重新运行的
full-gate
trace
脚本。该脚本读取当前已归档的实验摘要，连续重新计算
idea、evaluator、branch、program-search
和
claim
五类
gate
决策，并输出
JSON
与
Markdown
artifact。这证明
gate
policy
可以在当前证据包上被程序化执行；但它被明确标注为
executable
artifact
replay，而不是新的在线训练
run。

在
replay
artifact
之后，我们又在
ubuntu-heshi
上跑了一次新的
online
full-gate
smoke
trajectory。该
orchestrator
生成
idea
gate，审批低成本
evaluator
bundle，启动新的两
draft
FML-bench
Causality
frontier，选择验证
MAE
更低的分支，从所选
snapshot
继续运行一步
AI
Scientist-v2，同时在同一轨迹中跑一次一轮
OpenEvolve
knapsack
搜索，并写出
claim-audit
gate。branch
frontier
选择
step
2（验证
MAE
0.627837）而不是
step
1（验证
MAE
0.677448）。随后一
步
continuation
的
test
MAE
为
0.862015，差于所选
frontier
的
test
MAE
0.646224；同一轨迹中的
knapsack
OpenEvolve
smoke
达到

随后，我们为这条
online
smoke
增加了同
FML
step
数的
autonomous
baseline。该
baseline
使用同一个
Causality
任务和
DeepSeek
模型，运行三步
AI
Scientist-v2，但不进行人类
branch
gate。它得到验证
MAE
0.354147
和
held-out
test
MAE
0.428516，明显优于
human-gated
smoke
continuation
的
test
MAE
0.862015。因此，这个配对
smoke
结果对性能提升主张是负证据，但仍支持更窄的“在线
co-pilot
编排可以执行”这一主张。

随后我们把
same-continuous-trajectory
paired
online
full-gate
smoke
模式重复跑了三次，并直接从每条轨迹日志生成完整的
co-pilot
和
autonomous
manuscript
artifacts。其中两条
Causality
run
有有效标量测试指标：co-pilot
continuation
的平均
test
MAE
为
0.754120，同轮
autonomous
baseline
的平均
test
MAE
为
0.643337；在
lower-is-better
的
Causality
指标上，汇总结果是
0
次
co-pilot
benchmark
胜、1
次
autonomous
胜、1
次打平。第三条
run
切换到
Fairness_fairlearn，并被归档为
no-valid-branch
failure-mode
trajectory，co-pilot
和
autonomous
都没有得到有效标量测试指标。Monica
路由的
A/B
模型评审在三条轨迹的六次
reviewer
call
中都偏好
co-pilot

我们现在还补了一条
live
AI
Co-Scientist-style
hypothesis-frontier
smoke。该前端通过
Monica
路由的
gpt-4o-mini
做了两次真实模型调用：第一次为
IGRE
下一阶段证据里程碑生成
4
个候选
research
frontiers，第二次按
AI
Scientist-v2
的保守证据纪律对它们进行
critique
和
ranking。模型选择的下一预算候选是
frontier_004，即
structured
human
feedback
mechanism，用来比较
rubric-guided
feedback
和
informal
feedback
对
reproducibility
与
clarity
的影响。这个
artifact
缩小了
AI
Co-Scientist
部分的编排缺口：系统现在有了可记录的
generate-critique-rank
假设前端。但它还不能证明该候选会改善下游
benchmark
或论文质量，也不是一次人类选择结果。

随后，我们加入了一个
autonomous
hypothesis-front-end
baseline。脚本
run_hypothesis_frontend_baseline.py
复用已归档的
IGRE
candidate
portfolio，让同一个模型生成一个没有显式
human-taste
gate
或
structured
human
feedback
的
autonomous
AI
Scientist-v2-style
portfolio，再用固定
rubric
比较两个
portfolio。评分器偏好
IGRE（overall
4
vs.
3），理由是
IGRE
在
evidence
gain、benchmark
fit、claim
calibration
和
human-taste
visibility
上更强；但
autonomous
portfolio
在探索完全自动流程变体方面更强。这个
probe
只比较前端研究方向
portfolio，不能说明下游
benchmark、论文质量或人类专家判断更好。

因此，我们继续为
frontier_004
跑了一个小型
downstream
structured-feedback
probe。脚本
run_structured_feedback_probe.py
从同一份已归档
co-pilot
manuscript
出发，通过
Monica
路由的
gpt-4o-mini
做了
5
次真实调用：生成
free-form
informal
feedback、生成
IGRE-structured
feedback、分别基于两种
feedback
修订同一份稿件，并用固定
rubric
对两版修订进行模型评分。评分器偏好
structured-feedback
revision (overall
5
vs.
4)，并在
clarity、reproducibility、claim
calibration、evidence
grounding、method
distinctness、limitation
honesty
和
novelty
preservation
上给出更高分。这个结果只能被理解为
measurement-readiness
evidence：它说明
IGRE
feedback
格式可以被操作化，并能在模型路由评估中造成可测的稿件修订差异；它不是独立人类专家评审，也不是多
任务结果，更不能证明人类反馈提升
benchmark
performance。

为了检验公开专家评审数据能否作为“科研品味”的离线代理，我们又加入了一个
expert-review
taste-prior
probe。脚本
run_expert_review_taste_prior_probe.py
先检查
Hugging
Face
Dataset
Viewer
中
nhop/OpenReview
的可用性，再使用
streaming
方式抽样，因此不需要下载完整数据集。当前运行中，dataset
statistics
显示该
split
有
34,638
行，streaming
sample
取
160
篇论文；必需字段可用，包括
title、abstract、reviews、decision、mean_score、mean_novelty、mean_clarity、mean_impact
和
mean_reproducibility
等。在
160
条样本中，mean_score
覆盖
160
条、均值
0.5349；mean_novelty
覆盖
27
条、均值
0.6284；mean_correctness
覆盖
106
条、均值
0.6267；mean_clarity
覆盖
71
条、均值
0.5968；mean_impact
覆盖
73
条、均值
0.5459；mean_confidence
覆盖
158
条、均值
0.6373。样本中没有可用的
mean_reproducibility，这是构建
reproducibility score

这个定位使

OpenReview

数据可以服务于本文最重要的工作流设计问题。我们不把该数据集当作“在线人类

co-pilot

已经发生”的证据，而是把它作为

participation-mode

selection

benchmark：不同

workflow

variants

可以分别生成假设、实验计划、证据摘要或稿件修订，然后用

OpenReview-derived

rubric

检查这些

artifact

是否更接近高分专家评审论文的特征，例如

novelty、correctness、clarity、impact

和

reviewer

confidence。这样，本文就可以在同一个离线专家评价代理下比较不同人类参与模式：无

human

gate、上游

taste-prior

gate、evaluator-stress

gate、structured-feedback

gate

和

claim-calibration

gate。这个结果不能证明真实同行评审一定接收，但可以在更大规模在线研究数据出现之前，为选择相对更优的人机协作

workflow

提供实验数据支撑。

随后我们把这个想法实际跑成了

participation-mode

selection

experiment。脚本

run_participation_mode_selection_probe.py

让同一个模型为五种模式生成同任务

artifact：no

human

gate、taste-prior

gate、evaluator-stress

gate、structured-feedback

gate

和

claim-calibration

gate；评分调用则使用

expert-review

probe

中的

OpenReview

高分/低分样例作为

rubric

上下文。当前运行中，no-gate

artifact

overall

为

2, taste-prior

为

3, evaluator-stress

为

4, structured-feedback

和

claim-calibration

都为

5。评分结果在

best_mode

字段和

ranking

顺序上有一个小的不一致，因此本文不把它解读为唯一胜者，而是把

structured-feedback

与

claim-calibration

视为当前

top

pair。这个结果的设计意义是清楚的：真实评审风格信号最直接有用的位置，是改善稿件结构和削弱未被证据支持的主张；上游

taste-prior

仍然重要，但在这个

artifact-level

probe

中证据还不如后期结构化反馈和主张校准直接。

为了让“人类评审意见就是
taste/insight”不只停留在概念层面，我们又运行了
OpenReview-guided
regeneration
probe。脚本
run_openreview_guided_regeneration_probe.py
从样本中选择
3
篇适合
AI/ML
skill
的论文：一篇
LLM
refusal/RLKF
论文、一篇
in-context
learning
论文，以及一篇
semi-supervised/robust
learning
by
mixup
论文。对每篇论文，系统生成两个
mini-paper
artifact：baseline
只使用
title
和
abstract；review-guided
版本使用
title、abstract
加真实
OpenReview
review
snippets
和
decision
text。固定模型评分器在
3/3
个
pair
中都偏好
review-guided
artifact，mean
overall
从
3.0
提升到
4.0，平均增量
+1.0。这比单纯证明
OpenReview
数据可用更有实证价值：真实评审意见作为人类科研品味和
insight，确实改善了论文形态
artifact
的问题
framing、实验计划、局限性和主张校准。但它仍然没有重跑原论文实验，也不是独立专家复评。

最后, run_review_insight_taxonomy_probe.py
从
32
条
OpenReview
review
cases
中归纳哪些评审意见最适合作为自动科研控制信号。模型路由
taxonomy
把
novelty
concerns
与
limitations/weaknesses
标为高
actionability (5/5), 分别主要映射到
scientific-taste-prior
gate
和
claim-calibration
gate ; clarity
issues
的
actionability
为
4/5, 映射到
structured
feedback ; metric/evaluation
issues
的
actionability
为
4/5, 映射到
evaluator-stress
gate。这个
taxonomy
使
IGRE
的人类
taste/insight
更具体: 真正有用的评审意见, 是能改变
agent
该追踪什么问题、该补什么证据、该削弱哪些主张, 以及该如何更清楚呈现研究贡献的意见。

4.
Benchmark
选择与评估计划

我们计划比较六种系统版本：完全自动
baseline、仅创意节点介入、仅分支节点介入、仅评估器节点介入、仅论文主张审计介入，以及完整
co-pilot
v3。Benchmark
不应只局限于
FML-bench，而应根据论文主张分层选择。对于
AI
Scientist-v2
风格的实验搜索，FML-bench
是近期最合适的载体，因为它已经能在
Ubuntu
环境中跑通，并且能产生分支级日志。对于机器可评分的算法子问题，我们使用
OpenEvolve-controlled
tasks，例如函数最小化、0/1
knapsack
启发式搜索和加权
Max-Cut。对于
FML-bench
之外的更广泛证据，本文已加入一个
MLAgentBench
vectorization
小实验来测试端到端
ML
实验能力，并进一步记录了
MLAgentBench
CIFAR10/debug、MLAgentBench
IMDB
与
ScienceAgentBench
的
setup
probes。当前证据还没有第二个已打分的官方非
FML
benchmark：CIFAR10/debug
被慢速数据下载阻塞，IMDB
在补齐
datasets
依赖后仍因
Ubuntu
主机无法访问
HuggingFace
而失败，ScienceAgentBench
的元数据和
verified
artifacts
也暂时不可达。更高成本的
stretch
benchmark
包括
MLE-bench
Lite、PaperBench
和
AIRS-Bench：前者测试
Kaggle
风格
ML
engineering，PaperBench

指标包括任务分数、论文质量、主张支持率、搜索效率、人类注意力成本和假设多样性。对于程序化搜索模块，关键消融是：在相同 evaluator 和迭代预算下，比较 OpenEvolve 与直接重复 LLM 代码编辑。因此，FML-bench 应被理解为当前证据来源之一，而不是整个项目的完整 benchmark 定义。

因为 IGRE 的核心贡献是科研品味，而不是普通审批，本文在评估包中加入 taste/insight rubric。该 rubric 从 1 到 5 记录 problem depth、novelty potential、mechanistic value、failure informativeness、benchmark taste、claim significance 和 risk asymmetry，并要求写下简短理由。它刻意不被当作 reward model，而是记录导致人类保留、改写或剪枝某个分支的非指标先验。后续评估应同时报告平均任务表现和高尾部信号：例如一个 autonomous policy 本来会剪掉、但人类保留的分支，是否最终带来更强主张、更好 evaluator 或更有信息量的负结果。

我们也对
gate
records
加入
taste/insight
coverage
audit。因为本文的核心主张涉及人类科研品味，而不是普通
human
approval，所以仅靠公开
human-AI
interaction
数据并不够。我们检查了若干相邻公开数据集：CoAuthor
记录人类与
GPT-3
协作写作，CUPID
记录多轮偏好交互，neulab/agent-data-collection
汇总多类
agent
trajectories，WebChain
记录
human-annotated
web
trajectories；但这些数据都没有直接覆盖“人类科学家在
AI
Scientist-v2
风格假设—实验—论文循环中介入，并连接到
benchmark、代码
artifact、claim
audit
和
manuscript”的场景。因此本文把作者自己的
Codex
使用记录构造一个脱敏的
single-author
longitudinal
co-pilot
trace
corpus，只发布派生元数据层：gate
records、artifact
paths、commit
IDs、benchmark
metrics、manuscript
revisions
和
claim-audit
outcomes，而不公开原始聊天记录或密钥。当前派生快照包含
52
条
gate
records、35
条带
attention-cost
字段的记录、10
条带
taste/insight
字段的记录、4
个

根据最新
paper-quality
review
的意见，我们把人类注意力成本从口头指标变成了可审计
artifact。human-gate
schema
现在包含可选的
attention_cost
对象，用于记录
active
review
minutes、wall-clock
latency、reviewed
options、reviewed
artifacts
和
decision
count。我们还对现有
39
个
gate
records
做了严格
coverage
audit：其中包括
9
个
standalone
human-gate
logs，以及
6
个
trajectory
artifacts
中的
30
个
embedded
gates。结果是：当前只有
1
条完整
attention-cost
记录，即本轮
Codex
论文开发中
operator-recorded
的
measurement-readiness
gate，记录了
8.5
分钟
active
review、9.67
分钟
wall-clock
latency、3
个

为了让这一原则可以执行，我们维护了一份

benchmark-to-claim

matrix。

FML-bench

Causality

支持

branch-gate

可行性主张，但还不能证明人类

gate

整体优于

autonomous

baseline。FML-bench

Fairness

支持

evaluator

gate

的必要性，因为可执行性修复和退化预测器暴露了单指标投机风险。OpenEvolve

函数最小化、knapsack、Max-Cut、MLAgentBench

vectorization

和

sklearn

diabetes

probe

分别从不同子问题类型检验

program-search

escalation

policy。ScienceAgentBench、MLE-bench

Lite、PaperBench

和

AIRS-Bench

仍是下一阶段扩展目标，而不是当前已打分主张。因此，后续实验应按“最弱且尚未被支持的主张”来选择，而不是按哪个

benchmark

最方便来选择。

###

4.1

初步程序化搜索

smoke

test

作为可行性检查，我们已经在
SSH
控制的
Ubuntu
主机上运行了
OpenEvolve
0.2.27，并通过
OpenAI-compatible
API
调用
DeepSeek。任务是一个小型函数最小化
evaluator，初始程序为随机搜索。一次
OpenEvolve
迭代后，系统将
evaluator
分数从
0.0345
提高到
0.0378，并保存了一个模拟退火风格的
evolved
program。这个结果只是
smoke
test：它证明远程
OpenEvolve
路径、evaluator
加载、模型路由、checkpoint
和
artifact
捕获可以跑通，但还不能证明本文核心主张，即
human-gated
research
能提升最终论文质量。

我们还在相同
DeepSeek
模型、相同初始程序和相同
evaluator
下运行了
direct
one-shot
LLM-edit
baseline。该直接编辑基线得分为
0.038021，略高于一次迭代
OpenEvolve
的
0.037816，也略高于五次迭代
OpenEvolve
的
0.038007。这个边界结果支持
Co-Pilot
AI
Scientist
v3
的一个核心设计：程序化搜索不应该默认总是启动，而应该由明确的升级
gate
控制。对于极小预算或简单局部改写，直接编辑可能已经足够；当搜索空间更丰富、预算更大时，OpenEvol
ve
风格的种群搜索才更可能发挥价值。

为了测试后一种情况，我们进一步加入了一个更复杂的
0/1
knapsack
启发式任务。初始
value/weight
贪心程序在
18
个确定性实例上的平均最优比为
0.991519。direct
LLM
rewrite
将分数提升到
0.995270。五次迭代
OpenEvolve
进一步提升到
0.999439，且没有非法实例。进化出的程序加入了局部改进：移除一个或两个已选物品后，再用贪心方式重
新填充容量。这个结果为升级
gate
提供了正例：当子问题具有更丰富的组合结构，并且存在自动
evaluator
时，OpenEvolve-style
search
确实可能优于直接编辑。

为了避免只依赖一个手工

knapsack

结果，我们又加入了第二个受控组合优化任务：加权

Max-Cut。初始程序交替分配节点，在

16

个确定性图实例上相对于多起点局部搜索

reference

的归一化得分为

0.734680。一次

direct

DeepSeek

rewrite

将得分提升到

0.962237。使用相同模型和

evaluator

的五次迭代

OpenEvolve

run

达到

0.970833，比

direct

rewrite

高

0.008596，且没有非法实例。这个优势很小，而且只有一个

seed，但它给出了第二个算法子问题正例。结合函数最小化任务中的负边界结果，这更支持

selective

program-search

gate，而不是无条件启动

OpenEvolve。

###

4.2

AI

Scientist-v2

分支

gate

回放分析

我们还对已有的两个
AI
Scientist-v2/FML-bench
smoke
run
做了回放分析。在
Causality_causalm1
任务中，第一个
draft
就取得了四步运行中的最佳验证
MAE：0.598943，而原始
baseline
为
1.296259；第二个
draft
和后续
refinement
都没有超过它。如果在两个
draft
之后加入
branch
gate，人类会保留第一条分支，并避免至少一次低价值后续尝试。在
Fairness_fairlearn
任务中，第一个
draft
反而让公平性指标比
baseline
更差：0.316467
对比
baseline
0.186632；第二次尝试因为
Fairlearn
兼容性问题失败，后续尝试也要么更差、要么出错。此时
human
branch
gate
应暂停该分支，并把系统路由到
evaluator/兼容性修复或新的公平策略。这个回放证据还不能替代在线
human-gated
benchmark，但它说明
AI
Scientist-v2
的日志轨迹中已经存在适合人类
co-pilot
介入的可操作检查点。

###

4.3

在线

AI

Scientist-v2

分支

gate

小实验

为了从回放证据推进到在线证据，我们在

Ubuntu

主机上新跑了一次

FML-bench

小实验。任务仍为

Causality_causalm1。我们把

AI

Scientist-v2

设置为两步预算、两个

draft

idea、两个模拟并行

worker，并用临时

agent

配置把全部预算放到第一阶段，从而强制产生两个可比较的

draft

分支。第一个

draft

的验证

MAE

为

1.149610，第二个

draft

的验证

MAE

为

0.621262；该任务中

MAE

越低越好。因此，结构化

branch

gate

选择第二个

draft，并剪枝第一个

draft。benchmark

自动对最佳验证分支做最终测试，得到

test

MAE

0.640451。

这个在线小实验说明，本文提出的

branch

gate

可以插入真实

AI

Scientist-v2

决策前沿，并基于日志指标和代码快照做出清晰的预算分配决策。它还不能证明

human

gating

优于完全自动

AI

Scientist-v2：该实验尚未从被选中的分支继续

resume

进行后续

human-gated

search，而且其测试分数略弱于之前的四步

autonomous

smoke

run。因此，我们把它定位为在线人类介入可行性证据，而不是系统级优势的最终证据。

随后，我们实现了一个最小
selected-branch
continuation
runner。该
runner
会把人类
gate
选中的代码快照临时写回官方
FML-bench
任务模板，从该状态启动一个短预算
AI
Scientist-v2
continuation
run，并在结束后恢复模板文件。从被选中的第二个
draft
出发，继续两步后验证
MAE
达到
0.401240， test
MAE
达到
0.402170。这个结果优于
live
two-draft
gate
run
的
test
MAE
0.640451，也优于早期四步
autonomous
smoke
run
的
test
MAE
0.617719。这个比较仍然是初步的：当前
continuation
是通过
snapshot
seeding
实现的，还没有保存原始内存中的
tree
对象；同时它只覆盖一个小任务和一个
seed。因此，我们只把它作为“branch
gate
->
selected
snapshot
->
additional
AI
Scientist-v2
budget”这条路径可以执行的证据，而不是最终统计结论。

根据
paper-quality
review
的意见，我们又补了更接近同预算的
autonomous
baseline。第一组
matched
run
使用同一个
Causality_causalml
任务、同一个
DeepSeek
模型、两个初始
idea、两个并行分支和四个
AI
Scientist-v2
总步数，但不进行人类分支选择。它得到验证
MAE
0.389451、test
MAE
0.421474。在这一组中，human-gated
路径在
held-out
test
MAE
上略好：0.402170
对比
0.421474；但
autonomous
baseline
在验证
MAE
上略好。

随后我们又跑了第二组
matched
Causality
replicate。human-gated
两
draft
frontier
选择了验证
MAE
0.605881、test
MAE
0.646224
的分支；snapshot-seeded
continuation
没有进一步改善
held-out
test, 最终验证
MAE
为
0.627837、test
MAE
为
0.646224。对应的四步
autonomous
baseline
得到验证
MAE
0.537972、test
MAE
0.595685。在第二组中, autonomous
路径在验证集和
held-out
test
上都更好。

因此，两组同预算对照的结论是

mixed

evidence：一组

held-out

test

支持

human-gated

continuation，另一组支持

autonomous

baseline。两组平均后，human-gated

test

MAE

为

0.524197，autonomous

test

MAE

为

0.508579；由于该指标越低越好，均值反而略支持

autonomous

baseline。这个结果消除了一个重要的计算预算混淆因素，但不支持“人类

gate

普遍优越”的宽泛结论；它只支持

branch

gate

可以插入、selected

snapshot

可以继续搜索这一可行性主张。

我们现在还用脚本生成这组
FML
matched-comparison
aggregate，而不只依赖手写表格。生成的
audit
显示：两组正式
pair
中，human-gated
胜
1
次，autonomous/tie
胜
1
次；autonomous-minus-human
的平均
delta
为
-0.015618，delta
SEM
为
0.034921，并显式标注
statistical
claim
为
not_supported_n_too_small。单独的
online-smoke
comparison
对
co-pilot
performance
也是负结果：test
MAE
为
0.862015
对
0.428516。因此，这份脚本化
summary
是当前
FML
performance
evidence
的权威汇总。

在第二个
Causality
prospective
package
之后，我们又把同一个
package
runner
扩展到
ubuntu-heshi
上另一个实际可用的
FML-bench
workspace：Fairness_fairlearn。这个结果
同样不是
co-pilot
的正结果，但失败方式不同：co-pilot
branch
frontier
的两个候选都没有通过
validation，因此记录的
frontier
gate
选择
abort_no_valid_branch，而不是强行继续一个无效分支。
匹配的
autonomous
run
成功完成，test
primary
metric
为
0.172152
(abs_demographic_parity_diff_mean，越低越好)。当前
prospective
package
audit
因此覆盖
4
个
通过格式审计的
package：1
个受控
micro-task
正结果、2
个
Causality
FML
负结果，以及
1
个
Fairness
FML
无有效
continuation
的失败案例；四个
package
都包含完整的
attention_cost

4.4
非
FML
benchmark
与程序搜索小实验
根据上面的
benchmark
选择原则，我们还把
MLAgentBench
作为非
FML
评估来源。我们在
Ubuntu
主机上克隆
MLAgentBench，并先运行其轻量
vectorization
任务，使用内置
Agent
baseline。该
baseline
只执行
starter
train.py
并提交结果。官方
baseline
成功完成，final
score
为
3.172504
秒，total
benchmark
time
为
3.365531
秒，且没有错误标记。

随后，我们把同一个任务封装成更严格的本地
evaluator：在接受运行时间之前，evaluator
会用一个小型确定性输入，把候选
Conv2DLayer.forward
的输出和
nested-loop
reference
做数值比对。在这个受控
evaluator
下，starter
program
的
median
runtime
为
3.261186
秒。一次
direct
DeepSeek
deepseek-chat
rewrite
生成了看似合理的向量化代码，但因为数值不一致没有通过
correctness
gate。相反，使用同一
DeepSeek
模型的三轮
OpenEvolve-style
run
在第
1
轮找到了正确候选，median
runtime
为
0.051882
秒，相比受控
starter
program
约快
62.86
倍。这个结果支持一个较窄但重要的结论：program-search-escalation
节点可以在
FML-bench
之外的机器可评分子问题上发挥作用。但它还不能证明完整
co-pilot
架构能提升整篇论文质量。

为了检查稳健性，我们又用更多

random

seed

重复同样的三轮

OpenEvolve

设置。在

seed

0、1、2、3、4、7、42、123

共八次运行中，所有运行都保留了正确

best

program，并且都比受控

starter

更快。八个

seed

的

best

runtime

中位数为

0.024581

秒，相当于相对

starter

约

132.67

倍的中位加速；其中

6

个

seed

找到低于

0.1

秒的程序。这个结果明显强于最初的三

seed

probe，但仍不是确定性成功：seed

7

只有约

1.09

倍加速，seed

1

约

15.57

倍加速。因此，该结果增强了“程序搜索模块可以找到有效代码变换”的证据，同时保留了极小预算下

seed/budget

sensitivity

的重要

caveat。

为了避免非
FML
证据只覆盖底层
runtime
optimization，我们又加入了一个使用
sklearn
内置
diabetes
regression
dataset
的受控
tabular
modeling
probe。这个
probe
不需要
Kaggle
凭证，也不应被报告为官方
MLAgentBench
分数。初始程序是刻意粗糙的均值预测器，在五个确定性
split
上
mean
RMSE
为
78.572189。一次
direct
DeepSeek
rewrite
找回了标准
Ridge
风格
baseline，mean
RMSE
为
55.895460。三个三轮
OpenEvolve
seed
也都明显优于均值预测器，best
RMSE
分别为
55.895460、55.946535
和
55.895460；其中位
RMSE
为
55.895460，基本与
direct
rewrite
持平。这个结果把
benchmark
覆盖扩展到了表格建模子问题，同时也给出了重要边界条件：当改进只是一个标准的小型建模修改时，direc
t
editing
可以和
program
search

我们还尝试了三个
benchmark
扩展
probe。首先，我们尝试加入第二个官方
MLAgentBench
debug
任务，它映射到
CIFAR10。该
setup
probe
先修复了远端环境缺少
torchvision
的问题，并安装了与本地
torch
匹配的
CPU
wheel；但运行在数据准备阶段停止，因为
170
MB
的
CIFAR10
压缩包下载速度过慢，不适合当前交互预算。其次，我们检查了
ScienceAgentBench。该仓库已经存在于
Ubuntu
主机，README
指向
2026
年
4
月
verified
split
和
benchmark_verified.zip，但本地
benchmark
目录缺少
verified
artifacts，而且
HuggingFace
metadata
请求返回
[Errno
101]
Network
is
unreachable。第三，我们尝试官方
MLAgentBench
imdb
任务：补齐其官方
eval.py
需要的
datasets
依赖后，即使只加载
5
条测试样本也因为同样的
HuggingFace
网络错误失败。因此，本文只把这些记录为

###

4.5

主张审计

在完成这些
pilot
实验后，我们做了一次
claim-evidence
audit。通过
Monica
路由的
gpt-4o-mini
审稿式检查认为：本文的架构贡献是合理的，但当前实验证据还不足以支持“人类
gate
提高论文质量”或“完整
co-pilot
系统优于
autonomous
AI
Scientist-v2”这类宽泛结论。因此，本文把这些表述保留为
evaluation
protocol
要检验的假设，而不是已经证明的结论。当前
audit
只支持较窄的实证主张：OpenEvolve-style
search
可以在部分机器可评分子问题上有效，但在极小预算下存在
seed
sensitivity；direct
editing
在简单
tabular
modeling
probe
上可以匹配
OpenEvolve；branch
gate
可以插入
AI
Scientist-v2
风格日志轨迹；evaluator
gate
必须在
continuation
前拒绝无法执行以及指标投机的分支；两组
matched
Causality
对照给出的是混合证据，而不是稳定的人类
gate
优势。第一次把
online
branch
gate
扩展到
Fairness_fairlearn
时，两条候选都在
validation
阶段失败，因此本文只把它作为
failure-mode
evidence
归咎，而不足以

在加入
prospective
matched-budget
指标汇总后，我们又通过
Monica
路由刷新了两次
paper-quality
review。gpt-4o-mini
给出
weak-accept
建议，认为新颖性和可复现性较强，但严谨性和证据仍只有中等水平。claude-3-7-sonnet-latest
更严格，认为如果目标是强
ML/NLP
systems
venue，当前版本应被拒，因为核心
human-gating
和
paper-quality
主张仍未被证明，最强的
FML-bench
prospective
package
对
co-pilot
performance
是负结果，而且系统仍缺少
same-continuous-trajectory
的
paper-generating
对照。两个模型的共同结论是：下一版必须在更多任务和随机种子上比较
autonomous
AI
Scientist-v2
与
human-gated
variants，记录人类注意力成本，并更清楚地区分已经完成的系统证据和
future
work。

5.

当前贡献与尚未证明的主张

本文当前贡献包括：

1. 一个面向协作式自动科研的模块化架构。
2. 一个用于科研
agent
的人类参与节点形式化
schema。

3.
一条
live
Monica-routed
hypothesis-frontier
smoke, 生成
4
个新
research-frontier
candidates, 进行
critique/ranking, 并选择
frontier_004
作为可能的下一预算评估方向。

4.
一个
same-model
autonomous
hypothesis-front-end
baseline
probe, 比较已归档
IGRE
frontier
portfolio
与
autonomous
AI
Scientist-v2-style
portfolio, 并把
IGRE
评为
4、autonomous
评为
3, 但只作为前端
planning
evidence。

5. 一个基于
Hugging
Face
nhop/OpenReview
的
offline
expert-review
taste-prior
data
probe, 通过
streaming
方式从
34,638
行专家评审数据中抽样
160
行, 证明它可以支持有限的科研品味先验实验。
6. 一个
participation-mode
selection
probe, 使用
OpenReview-conditioned
scoring
比较
no-gate、taste-prior、evaluator-stress、structured-feedback
和
claim-calibration
五种模式, 当前把
structured-feedback
与
claim-calibration
识别为
top
pair。

7.

一个

OpenReview-guided

regeneration

probe, 选择

3

篇

ML/AI

论文, 用真实评审意见引导

mini-paper

artifact

再生成; review-guided

版本在

3/3

个

pair

中胜出, mean

overall

从

3.0

提升到

4.0。

8.

一个

review-insight

taxonomy

probe, 从

32

条

OpenReview

review

cases

中把

novelty

concerns、limitations/weaknesses、clarity

issues

和

metric/evaluation

issues

映射到

IGRE

gates。

9.
一个
same-manuscript
structured-feedback
probe, 将
frontier_004
操作化, 并通过两版修订与固定
rubric
模型评分比较
informal
feedback
和
IGRE-structured
feedback。
10.
一条
retrospective
full-gate
trajectory, 展示
idea、evaluator、branch、program-search
和
claim-audit
gate
都可以用同一
schema
记录。
11.
一个可重新运行的
full-gate
trace
脚本, 可以从已归档实验摘要中重新计算
gate
chain, 并明确把输出标记为
artifact
replay。
12.
第一条
online
full-gate
smoke
trajectory, 在一次远端运行中覆盖
idea、evaluator、branch、program-search
和
claim
gate, 同时记录了负向
continuation
结果。
13.
一个同时评估平均
benchmark
表现和人类参与下高尾部科研上限的实验协议。

14.
远程
OpenEvolve
与
FML-bench
小实验，证明可验证微演化和前沿转向两个
IGRE
算子可以在
Ubuntu
主机上运行。

15.
两组同预算
FML-bench
Causality
对照：human-gated
branch
continuation
与四步
autonomous
AI
Scientist-v2
baseline，结果呈混合状态。

16.
第一条
online
full-gate
smoke
的同
FML
step
autonomous
baseline，显示
human-gated
continuation
在该
smoke
对照中表现更差。

17.
两个非
FML
程序搜索小实验，分别覆盖
runtime
optimization
和
tabular
regression，用于扩展
FML-bench
之外的
benchmark
覆盖面。

18.
一个可在
Codex
中复用的
workflow
skill。
19.
中英文论文、使用文档和主张审计
artifact，便于复现和传播。
20.
Monica
路由的
paper-quality
review
artifact，用于记录下一轮修改前的外部模型批评。
21.
human-gate
attention-cost
audit，显示
39
条被审计
gate
中已有
1
条完整
operator-recorded
attention-cost
记录，另外
38
条仍不完整；未来
prospective
experiment
gate
必须补齐这些字段后，才能提出
attention-efficiency
claim。
22.
taste/insight
coverage
audit，显示当前已有
2
条完整
scientific-taste
prior
记录，另有
37
条
gate
仍缺少完整
taste/insight
字段。

23.
prospective
matched-budget
package
validator, 用来定义在声称论文质量提升、人类注意力效率提升或优于
autonomous
AI
Scientist-v2
之前, 最低限度需要具备的非
synthetic
证据形状。

24.
一个
controlled
prospective
Max-Cut
micro-pilot
package, 已经通过该
validator, 并包含完整
attention/taste
logging、matched
baseline
metrics、claim
audit
和同次运行生成的
manuscript
artifact。

25.
一个
prospective
FML-bench
Causality
package, 包含完整
attention/taste
logging
和
matched
autonomous
baseline; 在这个两步小预算设置中, co-pilot
test
MAE
为
0.646224, autonomous
baseline
为
0.624703, 因此是负向
co-pilot
performance
结果。

26.

一个

prospective

package

指标汇总表, 把通过

audit

的

package

按任务、指标方向、co-pilot

分数、autonomous

分数和

claim

implication

汇总; 当前结果是

1

个

controlled

micro-task

正向结果、2

个

Causality

FML-bench

负向结果, 以及

1

个

Fairness_fairlearn

无有效

continuation

的失败案例。

27.

一个

matched

mini-manuscript

quality

probe：为同一个

FML

package

生成

autonomous

mini-manuscript, 并让

Monica

路由的

gpt-4o-mini

和

claude-3-7-sonnet-latest

对匿名

A/B

manuscript

评分；两个模型都偏好

co-pilot

package

mini-manuscript, overall

为

4

对

3。

28.

一个

matched

full-manuscript

generation

probe：把同一个已归档

FML

evidence

package

渲染成两篇完整论文形态的

manuscript，并用确定性内部

rubric

评分；最新

Fairness

package

中，co-pilot

manuscript

因结构完整、证据绑定、主张校准和方法区分度得到

4.18

overall, autonomous

manuscript

得到

4.11

overall, 但

autonomous

是唯一拥有有效

FML

标量测试指标的路径。

29.

一个
repeated
same-continuous-trajectory
paired
online
full-gate
manuscript-production
汇总，覆盖三条
smoke
run，其中包括一条
Fairness_fairlearn
no-valid-branch
failure
trajectory；有效
Causality
benchmark
汇总为
0
次
co-pilot
胜、1
次
autonomous
胜、1
次打平，而
Monica
路由模型评审在
6/6
次
reviewer
call
中偏好
co-pilot
manuscript。

30.

一个
Human
Co-Pilot
Trace
Dataset
protocol，把本文实际
Codex
使用记录转化为脱敏派生数据集，而不是依赖不匹配的通用
human-AI
interaction
数据集。

当前证据还不能证明人类

gate

能提升论文质量，也不能证明完整

co-pilot

系统优于

autonomous

AI

Scientist-v2。structured-feedback

probe

只是单篇稿件上的

measurement

artifact，不能替代独立专家评审。这些更强主张仍是下一阶段

benchmark

要验证的目标。

6.

局限性

本文不预设人类参与一定有效。人类

gate

可能引入偏见、降低搜索速度、压缩探索多样性；在短预算

benchmark

中，它甚至可能不如完全自动搜索策略。这不是附带

caveat，而是本文方法需要正面评估的一部分。IGRE

把人类科学家视为高方差搜索算子，其价值可能不体现在平均分上，而体现在高尾部：更好的问题品味、更能揭示机制的

evaluator、更尖锐的失败解释，或者愿意追踪一个更冒险但更原创的方向。程序化搜索也可能只优化局部指标，却不能提高论文层面的科学贡献；在极小预算下，它也未必优于直接

LLM

编辑。专家论文评分成本较高，而且不同评审可能存在分歧。因此，第一版实验应保持窄主张，并在

gate

无法改善结果时如实报告负结果。当前

selected-branch

continuation

证据在两组

matched

pair

中呈混合状态，还不是统计受控

benchmark；retrospective

full-gate

trajectory

和

executable

artifact

replay

证明了

schema、决策链和可复现

traversal

logic。online

smoke

trajectory

已经在一次远端运行中覆盖五类

gate，但预算极小、混合了

FML

branch

task

和

knapsack

program-search

子问题，并且

continuation

test

score

变差；同

FML

step

autonomous

baseline

也优于

human-gated

continuation。更强主张需要更多任务、更多随机种子、更丰富的预算分配设置、更大规模在线轨迹、独立论文质量评审，以及能捕捉少数高质量科研结果的指标，而不只是平均任务分数。

当前
human-gate
logs
也缺少可度量的人类注意力成本。我们可以统计决策
artifact, 但还不能计算
active
review
minutes
或
wall-clock
latency, 因此不能声称
gate
提高了单位人类努力产出的科研质量。下一轮
matched-budget
实验必须前瞻性记录
attention
cost。
新的
prospective
matched-budget
package
audit
现在已经在
controlled
micro-pilot、两个
FML-bench
Causality
pilot
和一个
FML-bench
Fairness
pilot
上通过。这个进展说明最小证据形状可以被真实远端计算生成和审计, 而且已经延伸到
AI
Scientist-v2
风格
benchmark ; 但
FML
packages
在当前小预算设置中都是
co-pilot
平均性能的负结果或无有效
continuation
的失败案例, 且这些
package
仍没有独立评价完整论文质量。因此当前论文仍应被限制在
pilot-system
evidence, 直到更多任务、更多
seed、更大预算和独立论文质量评审完成。

我们还新增了
package
指标汇总，而不只报告
artifact
audit
是否通过。当前四个
passing
package
中，controlled
Max-Cut
micro-task
的
human-selected
branch
在
mean
normalized
score
上胜出（0.984419
对
0.596214），但这只是微任务；两个
FML-bench
Causality
package
都由
autonomous
baseline
在
test
MAE
上胜出，分别为
0.624703
对
0.646224，以及
0.296399
对
0.646224；Fairness_fairlearn
package
中
co-pilot
frontier
没有有效测试分数，而
autonomous
baseline
的
primary
metric
为
0.172152。四个
human
gate
都已经记录完整
attention-cost
和
taste/insight。这个结果正是
IGRE

我们还补了第一个
matched
mini-manuscript
quality
probe。该
probe
从同一个
FML
package
的
autonomous
baseline
生成一篇
autonomous
mini-manuscript，把
co-pilot
package
manuscript
匿名为
A，把
autonomous
manuscript
匿名为
B，并让
Monica
路由的
gpt-4o-mini
和
claude-3-7-sonnet-latest
按
claim
calibration、evidence
use、methodological
completeness、limitation
honesty、clarity
和
overall
quality
评分。两个模型都偏好
A，overall
为
4
对
3；理由是
co-pilot
mini-manuscript
虽然
benchmark
分数更差，但对主张边界和局限性写得更清楚。这个结果只能说明
manuscript-quality
measurement
pipeline
可运行，不能证明完整
co-pilot
系统已经能写出更好论文。

这次新增的
full-manuscript
probe
只缩小了一个具体缺口，并没有关闭顶会证据缺口。它说明已归档
FML
package
中的结构化证据足以生成两篇完整、主张校准的论文形态
manuscript；最新
Fairness
probe
中
co-pilot
manuscript
的内部
rubric
为
4.18, autonomous
manuscript
为
4.11, 但
autonomous
是唯一拥有有效
FML
标量测试指标的路径。更新的
repeated
same-continuous
online
smoke
summary
进一步说明
fresh
online
co-pilot
trajectory
可以生成完整论文形态
artifact，并且可以同轮生成
autonomous
manuscript
comparator；但两条有效
Causality
paired
smoke
的
benchmark
汇总为
0
次
co-pilot
胜、1
次
autonomous
胜、1
次打平，mean
test
MAE
为
co-pilot

taste/insight

证据目前也只是

logging-readiness

阶段。归档中已有

2

条完整

scientific-taste

prior

记录：一条来自作者要求扩展

benchmark

并突出高尾部科研品味的指令，另一条来自本轮

operator-recorded

决策，即优先补

attention/taste

测量，而不是继续堆弱

benchmark

运行。但这两条记录都还不能证明该决策改善了下游科研结果。下一轮实验必须前瞻性记录

taste

rationale，才能检验人类

insight

是否真的改变了科研搜索分布。

作者自己的
Codex
科研轨迹只能作为单作者
ecological/process
case, 数据量和主体多样性都太小, 不应该作为主要实证数据来证明“人类参与自动科研会提升结果”。OpenReview/Hugging
Face
专家评审数据则确实是人类科研
taste
和
insight
的真实文本化数据, 但它是离线、异步的评审数据, 而不是实时
co-pilot
交互轨迹。它可以用于
artifact
regeneration、participation-mode
selection
和
review-insight
taxonomy, 本文新增的三个
OpenReview
probes
就是在做这件事; 但它还不包含人在自动科研过程中实时改变搜索前沿的行为。真正有力的在线
human-guided
automated-science
数据需要一个被大量科研人员长期使用的
skill
或科研
assistant, 在取得同意和脱敏后前瞻性记录人类介入、attention
cost、artifact
links、后续
benchmark
和论文质量结果。现阶段这类数据更可能由主流
agent
公司或大模型平台通过大规模产品化系统收集; 本文只能把它作为重要
future
work, 而不是当前已完成证据。

当前实现现在已有

smoke

级别的

repeated

same-continuous-trajectory

在线论文生成对照，但规模仍不足以支撑

systems

paper

的强主张。下一版

systems

paper

至少需要报告多组更大规模的

matched

在线轨迹，覆盖更多任务和随机种子，从假设生成一直到最终

claim-audited

manuscripts。

7.

结论

Co-Pilot

AI

Scientist

v3

将自动科学发现重新定义为洞察门控科研演化。该系统保留自动

agent

的大规模搜索能力，同时给人类科学家提供明确、可记录、可实验检验的影响节点。它最重要的主张不是“人类总能提高平均

benchmark

表现”，而是人类科研品味和

insight

可以改变搜索分布，使系统更有机会产生少数但更原创、更可能开创新方向的成果。如果未来

matched

benchmark

支持这一高尾部假设，co-pilot

科研系统可能通过改变“系统尝试什么样的科学”来写出更好的论文，而不是简单把人类排除在科学之外。

当前论文应被理解为一个带

pilot

evidence

的可复现系统

proposal，而不是最终优越性证明。